

目 录

摘要	ii
Abstract	iii
第一章 引言	2
1.1 研究背景与意义	2
1.1.1 分布外泛化 (OOD) 与因果特征学习的兴起	2
1.1.2 大规模神经网络在变分推断下面临的算力瓶颈	2
1.2 现有因果学习算法的缺陷	3
1.2.1 全参数贝叶斯采样的巨大开销	3
1.2.2 高维参数空间下的优化坍缩与适配鸿沟	3
1.3 主要研究内容与贡献	4
1.3.1 参数高效因果学习架构的设计与实现	4
1.3.2 高维优化动力学分析与正则化机制	4
1.3.3 多尺度模型与分布偏移场景下的泛化验证	5
1.4 本文组织结构	5
第二章 预备知识与相关工作	6
2.1 因果泛化基础: 从 IRM 到 BIRM	6
2.1.1 IRM 的环境视角与基本目标	6
2.1.2 BIRM 的提出与坍缩修复	6
2.1.3 SparseIRM 与结构性容量瓶颈的启发	7
2.2 低秩参数化基础: 从 PEFT 到因果正则化	7
2.2.1 LoRA 的参数高效适配机制	7
2.2.2 低秩约束为何能够抑制虚假特征	7
2.3 变分推断与高维优化基础	8
2.3.1 ELBO 目标与重参数化技巧	8
2.3.2 高维因果优化的动力学困难	9
2.4 本章小结	9
第三章 核心架构设计: LoRA-BIRM	10
3.1 架构设计思路与计算解耦	10
3.1.1 确定性骨干提取与随机性低秩采样	10
3.1.2 联合损失函数重构与惩罚计算优化	11
3.2 优化动力学控制: 平滑权重退火机制	11
3.2.1 传统固定惩罚权重下的休克疗法缺陷	12

3.2.2	线性动态退火策略 (Linear Annealing) 的设计	12
3.3	工具链与代码库建立	13
3.3.1	贝叶斯 LoRA 分类头的参数化构建	13
3.3.2	差分学习率与全量分批测试逻辑注入	13
第四章	理论动机与规模分析: 从 IRM/BIRM 到低秩参数化	15
4.1	本文后续采用的 LoRA-BIRM 标准化定义	15
4.1.1	标准化定义	15
4.2	IRM 的线性理论背景与有限样本偏离	16
4.2.1	线性一般位置假设与可识别性结果	16
4.2.2	这些结果的适用范围	16
4.2.3	有限样本与过参数化下的插值问题	17
4.3	BIRM 的理论动机与参数维度问题	17
4.3.1	过拟合区域与 IRM/IRMv1 的退化现象	17
4.3.2	BIRM 为何可能缓解退化	18
4.3.3	大模型场景下 KL 项的规模增长	18
4.4	低秩参数化的作用: 容量控制与复杂度缩放	18
4.4.1	低秩更新带来的有效自由度收缩	19
4.4.2	只在小参数子空间上做变分推断时的 KL 缩放	19
4.5	本章不声称的内容	20
4.6	本章小结	21
第五章	核心机理仿真与验证 (基于 Colored MNIST)	22
5.1	实验设置与对比方法	22
5.1.1	因果视觉任务定义: 引入虚假颜色的 CMNIST	22
5.1.2	四种方法的训练方式与评估协议	22
5.2	主结果: OOD 表现、成本趋势与机制解释	23
5.2.1	五次独立运行的 OOD 精度对比	23
5.2.2	Route A 与 Route B 的差异解释	24
5.2.3	小规模平台上的训练代价比较	24
5.2.4	精度与稳定性的联合观察	25
5.3	本章结论与向第六章的过渡	25
5.3.1	CMNIST 实验得出的三个结论	25
5.3.2	为何需要进入 Spurious CIFAR	26
第六章	复杂场景扩展与稳定性实测 (基于 Spurious CIFAR)	27
6.1	实验设置与评估口径	27
6.1.1	Spurious CIFAR 任务构造与环境划分	27
6.1.2	对比方法、随机种子与报告口径	28
6.2	完整训练基线: ERM、IRMv1 与 BIRM	28
6.2.1	五种子最终精度与过程最佳精度	28

6.2.2	训练动力学解释	29
6.3	低秩快照式 LoRA-BIRM: 设计动机与训练流程	29
6.3.1	总体思路	29
6.3.2	训练目标与环境约束	30
6.3.3	快照选择与训练流程	31
6.4	低秩快照实验: 五种子结果、局部高峰与预算折中	31
6.4.1	已归档的五种子快照主结果	31
6.4.2	种子级别高峰与训练末端回落	32
6.4.3	预算压缩与精度折中	32
6.5	稳定性边界与失败模式	33
6.5.1	平均精度掩盖的最差环境问题	33
6.5.2	为何低秩搜索会出现高峰但不稳定	34
6.6	本章结论	34
6.6.1	复杂场景下已经成立的结论	34
6.6.2	仍待解决的问题与后续方向	35
第七章	Qwen 平台上的四算法对比实验与分析	36
7.1	数据构造、环境划分与评估协议	36
7.1.1	shortcut 训练集的构造方式	36
7.1.2	反转测试集的定义	37
7.2	四种算法的训练方式与运行配置	37
7.2.1	四种算法的训练方式	37
7.2.2	统一评估协议与 LoRA-BIRM 超参数	37
7.3	结果一: 四种算法的总体结果对比	38
7.4	结果二: LoRA-BIRM 的训练动力学与快照现象	39
7.5	结果分析与讨论	40
7.5.1	为何 LoRA-BIRM 可能高于冻结式基线的历史峰值	40
7.5.2	为何最佳结果出现在前半程而非训练末端	40
7.5.3	Qwen 实验对全文结论的补充意义	41
7.6	本章小结	41
第八章	总结与展望	42
8.1	本文总结	42
8.2	未来研究方向	42
	参考文献	45
	致谢	47

摘要

分布外泛化 (OOD) 任务中的核心困难在于, 深度模型往往会依赖训练环境中与标签共现但不稳定的虚假特征, 从而在测试分布发生偏移时迅速失效. 不变风险最小化 (IRM) 及其贝叶斯扩展 (BIRM) 为这一问题提供了因果约束视角, 但当它们被直接迁移到深层卷积网络和大语言模型时, 又会面临全参数变分推断开销过高、强惩罚下优化不稳定以及模型选择噪声较大的现实困难. 针对这些问题, 本文提出并整理了一条以低秩参数化、贝叶斯环境约束与快照保留为核心的 LoRA-BIRM 实现路线. 该路线通过将可训练随机性限制在较小参数子空间中, 把不变性训练从“全参数收敛”改写为“受限预算下的高质量解搜索”问题, 并辅以完整评估、EMA 与历史最优快照保留机制来提高模型选择的可靠性.

本文首先在线性理论、参数自由度与 KL 项缩放三个层面说明: 低秩参数化并不能直接保证因果恢复, 但它能够压缩可训练自由度和贝叶斯化参数规模, 因而为大模型上的不变性约束提供了一个更可执行的工程化近似. 随后, 本文在 Colored MNIST、Spurious CIFAR 和 Qwen 三类平台上进行了实验验证. 结果表明: 在 CMNIST 上, 低秩贝叶斯路线能够在保持较好 OOD 精度的同时不增加训练代价; 在 Spurious CIFAR 上, 当前已归档的五种子快照结果在平均历史峰值上与 BIRM 的过程最佳均值基本持平, 但个别种子能够达到更高局部峰值, 且在相同诊断协议下以更短训练预算完成搜索; 在 Qwen 平台上, LoRA-BIRM Snapshot 在相近 time-to-best 的条件下记录到了最高的历史峰值, 说明受限底座适配与快照保留在大模型 shortcut 纠偏中具有可观价值. 与此同时, 更保守的多种子与训练末端子群观察也显示, 当前方法在最差种子和最差环境稳定性上仍未完全解决. 因而, 本文最终主张是审慎的: LoRA-BIRM 当前最可靠的贡献, 是展示了低秩贝叶斯因果微调在高质量局部峰值搜索和训练预算压缩方面的潜力, 而不是证明其已在所有设置下稳定优于现有基线.

关键词: 大语言模型; 参数高效微调; 低秩适配 (LoRA); 不变风险最小化 (IRM); 贝叶斯变分推断; 分布外泛化

Abstract

The main difficulty in out-of-distribution (OOD) generalization is that deep models often rely on spurious features that co-occur with labels in the training environments but do not remain stable under distribution shift. Invariant Risk Minimization (IRM) and its Bayesian extension BIRM provide a causal perspective on this problem, yet their direct application to deep convolutional networks and large language models faces substantial practical obstacles, including the cost of full-parameter variational inference, unstable optimization under strong invariance penalties, and noisy model selection. To address these issues, this thesis develops a LoRA-BIRM implementation route centered on low-rank parameterization, Bayesian environment-aware regularization, and snapshot retention. By restricting trainable randomness to a much smaller parameter subspace, the method turns invariance training from a problem of full-parameter convergence into one of searching for high-quality solutions under limited budget, while using full-set evaluation, EMA, and best-snapshot retention to improve selection reliability.

From the perspectives of linear-theory motivation, effective degrees of freedom, and KL scaling, the thesis argues that low-rank parameterization should not be interpreted as a guarantee of causal recovery, but rather as a more executable engineering approximation for bringing invariance constraints to large models. Experiments are conducted on Colored MNIST, Spurious CIFAR, and a Qwen-based shortcut setting. On CMNIST, the low-rank Bayesian route maintains competitive OOD performance without increasing training cost. On Spurious CIFAR, the strongest evidence is not that LoRA-BIRM already stably surpasses BIRM, but that the archived five-seed snapshot results reach a process-best mean comparable to BIRM while some seeds attain higher local peaks under a shorter training budget. On Qwen, LoRA-BIRM Snapshot records the highest historical peak at a similar time-to-best, suggesting that restricted backbone adaptation together with snapshot retention has observable value in shortcut correction for large models. At the same time, more conservative multi-seed and end-of-training subgroup diagnostics show that stability on the worst seeds and worst environments is still unresolved. Therefore, the most reliable contribution of this thesis is a cautious one: LoRA-BIRM currently demonstrates practical potential for high-quality local peak search and budget-efficient causal fine-tuning, rather than a definitive claim of stable superiority over existing baselines across all settings.

Keywords: Parameter-Efficient Fine-Tuning; Low-Rank Adaptation (LoRA); Invariant Risk Minimization (IRM); Bayesian Inference; Out-of-Distribution Generalization

CLC code: TP391

第一章 引言

1.1 研究背景与意义

1.1.1 分布外泛化 (OOD) 与因果特征学习的兴起

近年来, 深度神经网络在计算机视觉、自然语言处理等多个领域取得了突破性进展, 甚至在特定任务上超越了人类水平. 然而, 这些卓越的性能高度依赖于一个基础的统计学假设: 训练数据与测试数据满足独立同分布 (Independent and Identically Distributed, I.I.D.) 条件^[1]. 在实际的开放世界应用中, 由于数据采集的设备、时间、地理位置及背景环境的不断变迁, 测试数据的分布往往会发生不可预知的偏移 (Distribution Shift). 当面对这种分布外 (Out-of-Distribution, OOD) 数据时, 传统深度学习模型的预测性能常常会出现断崖式的下降^[2].

导致模型泛化能力退化的根本原因在于, 传统基于经验风险最小化 (Empirical Risk Minimization, ERM) 的训练范式倾向于以“贪婪”的方式最小化训练误差. 在这种机制下, 模型极易捕获数据中与标签高度共现, 但并无实质因果联系的“虚假关联 (Spurious Correlations)”^[3]. 例如, 在图像分类任务中, 若训练集里的“牛”大多出现在绿草地上, 模型可能会捷径式地将“绿色背景”的纹理特征与“牛”的标签强绑定. 一旦在测试集中遇到“沙滩上的牛”, 模型便无法进行正确识别^[4]. 这种依赖数据集特有统计偏差进行“捷径学习 (Shortcut Learning)”的现象, 极大限制了人工智能在自动驾驶、医疗诊断等高风险领域的安全落地.

为了打破纯统计相关性的局限, 学术界开始将目光投向因果推断 (Causal Inference), 由此促生了“因果特征学习 (Causal Feature Learning)”这一新兴研究热点^[5]. 因果学习的核心思想是引导模型摒弃环境中易变的虚假关联 (如图像背景、颜色偏见), 转而挖掘跨环境保持绝对不变的真实“因果特征” (如物体的几何轮廓、语义逻辑等)^[6].

在此背景下, Arjovsky 等人提出了不变风险最小化 (Invariant Risk Minimization, IRM) 框架^[7]. IRM 摒弃了将所有数据混合池化训练的传统方式, 转而引入了“环境 (Environment)”的概念. 它假设无论数据的表层分布如何改变, 因果特征与标签之间的映射机制应尽量保持稳定. 因此, IRM 通过在目标函数中施加跨环境的损失方差或梯度一致性约束 (Invariance Penalty), 试图引导网络提取出在多个训练环境中都能支持同一分类规则的表征. 这一思路为 OOD 泛化问题提供了一个清晰的理论视角, 并进一步催生了包括方差外推风险最小化 (V-REx)^[8] 以及本文所关注的贝叶斯不变风险最小化 (BIRM)^[9] 等一系列后续方法.

1.1.2 大规模神经网络在变分推断下面临的算力瓶颈

近年来, 深度学习已经进入大模型 (Foundation Models) 阶段. 无论是计算机视觉中的深层残差网络 (ResNet) 与视觉 Transformer (ViT), 还是自然语言处理中的大语言模型 (LLM), 其参数规模都在持续增长^[10]. 庞大的参数量提升了模型的拟合能力与任务迁移能力, 但并未自动消除模型对数据中“虚假关联”的依赖. 因而, 如何将因果泛化中的不变性思想迁移到大规模预训练模型, 仍然是一个值得研究但尚未充分解决的问题.

然而,理想的理论在向工程界迁移时,往往会遭遇严酷的物理现实.纵观当前因果泛化领域的最新文献,绝大多数经典算法(包括传统的IRM以及贝叶斯变分推断版本)的实证研究,依然高度局限于浅层多层感知机(MLP)或基础的微型卷积架构,实验环境也多为结构简单的Colored MNIST等人工合成数据集^[11].

当研究者试图将这些复杂的因果约束(如跨环境的方差惩罚或梯度对齐)直接套用于现代深层神经网络时,极易触发难以逾越的“算力墙(Compute Wall)”.尤其是在引入贝叶斯变分推断来对抗“特征坍塌”时,传统的全参数优化范式对算力和显存的需求超出了现有常规硬件的承受极限.这种学术理论与工程规模之间的巨大“技术断层(Technical Gap)”,使得大模型在面对复杂的分布偏移时依然缺乏有效的因果约束手段^[12].

因此,如何在千亿级参数的汪洋大海中,以可接受的算力成本高效地寻找到那条绝对不变的“因果路径”,使得深层神经网络能够真正受惠于贝叶斯因果理论,构成了本课题研究的最核心宏观动机.

1.2 现有因果学习算法的缺陷

1.2.1 全参数贝叶斯采样的巨大开销

在因果学习的贝叶斯扩展方案中,变分推断(Variational Inference, VI)是实现模型参数不确定性估计的核心机制^[13].以贝叶斯不变风险最小化(BIRM)为例,算法不再将神经网络的权重视为固定的点估计(Point Estimate),而是假设其服从某种参数化的先验分布(如高斯分布).在训练过程中,模型通过优化证据下界(Evidence Lower Bound, ELBO),不断逼近真实的后验分布^[9].这种机制虽然在对抗极端不变性惩罚(Invariance Penalty)时展现出了卓越的抗坍塌能力,但其代价是引入了极其沉重的采样开销.

具体而言,在全参数微调(Full-Parameter Fine-Tuning)范式下,网络的前向传播(Forward Pass)必须依赖于重参数化技巧(Reparameterization Trick)来实现梯度的反向传播.这意味着对于一个包含 N 个参数的深度神经网络,优化器不仅需要额外维护 N 个方差参数,还需要在每一次迭代时实时生成 N 个高斯随机噪声变量.当模型规模从简单的多层感知机(MLP)扩展到包含数千万甚至数十亿参数的现代架构(如ResNet或Transformer)时,这种逐参数(Parameter-wise)的随机采样操作会导致显存占用率瞬间飙升至原本的三倍以上^[14].

更为严峻的是,为了获得足够准确的期望梯度估计,变分推断通常需要在单次参数更新中进行多次蒙特卡洛(Monte Carlo)前向采样.这种成倍增加的计算负担,使得全参数BIRM在处理高维图像或长文本数据时,训练耗时呈指数级爆炸.算力瓶颈已经成为了阻碍因果泛化算法从“玩具数据集(Toy Datasets)”走向工业级大模型的最主要物理屏障.因此,探索一种能够在大幅压缩采样维度的同时保留贝叶斯不确定性探索能力的新型架构,成为了不可回避的工程挑战.

1.2.2 高维参数空间下的优化坍塌与适配鸿沟

除了前文所述的硬件算力爆炸,传统的全参数不变风险最小化(IRM)及其贝叶斯扩展方案在向深层神经网络迁移时,还面临着极其严峻的优化动力学(Optimization Dynamics)挑战.

在浅层多层感知机(MLP)或微型卷积网络中,模型的参数容量(Capacity)相对有限.当算法在目标函数中施加强烈的不变性惩罚(Invariance Penalty)时,模型依然能够在有限的特征空间内找到跨环境一致的因果特征.然而,当底座模型升级为包含千万级乃至百亿级参数的深度架构(如

ResNet 或 Transformer) 时, 极高维的参数空间赋予了优化器过度的自由度 (Degrees of Freedom)^[9].

在因果学习的博弈中, 预测损失 (Predictive Loss) 与环境方差惩罚往往存在剧烈的梯度冲突. 在极高的惩罚权重压迫下, 高维空间中的优化器为了以最快速度将环境间的损失方差“归零”, 往往会倾向于寻找一条投机取巧的捷径: 抹除所有学到的特征表示, 使得网络输出退化为平庸的常数或接近随机猜测的零解^[3]. 这种在高维过参数化 (Over-parameterization) 状态下极易触发的“梯度坍塌 (Gradient Collapse)”现象, 导致全参数深层网络在因果泛化任务中表现出极不稳定的收敛轨迹, 经常在训练初期便陷入非预测性的退化解 (Degenerate Solution).

因此, 无论是从计算预算的约束出发, 还是从缓解高维优化不稳定性的需求出发, 全参数微调都不是实现这类方法的唯一选择. 一个更实际的问题是: 能否为因果约束过程引入某种“结构性瓶颈 (Structural Bottleneck)”, 使不变性约束只作用在一个更小、更可控的参数子空间中. 这促使我们将目光投向参数高效微调 (PEFT) 技术, 特别是低秩适配 (LoRA)^[15]. 若能将贝叶斯变分推断下放至低秩适配器子空间中进行, 那么它至少可能同时带来两方面好处: 一是减轻计算与显存压力, 二是通过限制可训练自由度来抑制对高维虚假关联的过度拟合. 本文的工作正是围绕这一思路展开.

1.3 主要研究内容与贡献

针对传统贝叶斯不变风险最小化 (BIRM) 算法在深层神经网络中面临的算力瓶颈与优化不稳定问题, 本文尝试将参数高效微调 (PEFT) 技术引入因果泛化场景, 并围绕“低秩参数化是否能为不变性训练提供更可控的实现方式”这一问题展开分析与实验. 更保守地说, 本文的工作可以概括为以下三个方面:

1.3.1 参数高效因果学习架构的设计与实现

本文给出了一种将低秩适配 (LoRA) 与 BIRM 思路结合的实现框架. 在该框架中, 预训练底座权重 $W_0 \in \mathbb{R}^{d \times k}$ 被冻结, 作为确定性的特征提取器; 与分布偏移相关的任务适配与随机性建模, 则被限制在低秩适配器所构成的较小参数子空间中. 其前向传播的权重更新量被参数化为:

$$\Delta W = BA, \quad \text{其中 } A \in \mathbb{R}^{r \times k}, B \in \mathbb{R}^{d \times r}, r \ll \min(d, k). \quad (1.1)$$

在这一设定下, 算法的优化目标可以写成在低秩空间中寻找满足不变性约束的参数增量:

$$\min_{A, B} \sum_{e \in \mathcal{E}_{tr}} \mathcal{L}^e(W_0 + BA) + \lambda \cdot \mathcal{R}_{inv}(W_0 + BA), \quad (1.2)$$

其中 $\mathcal{L}^e$ 为环境 e 下的经验风险, $\mathcal{R}_{inv}$ 为跨环境的一致性惩罚项. 这一设计的主要目的, 是把原本作用于全参数空间的随机性与不变性约束压缩到一个更小的子空间中, 从而降低实现成本并改善训练可控性.

1.3.2 高维优化动力学分析与正则化机制

在分析层面, 本文从参数自由度与 KL 项缩放的角度讨论了低秩参数空间在强不变性惩罚下可能带来的影响. 相关分析表明, 极低秩的参数空间容量 (Capacity Bottleneck) 可以被看作一种结构性的容量控制, 它未必直接保证因果恢复, 但有助于限制模型对高频虚假关联噪声 (Spurious Correlations) 的记忆能力.

同时, 针对固定高惩罚权重容易诱发“特征坍缩 (Feature Collapse)”与“优化停滞”的现象, 本文采用并验证了平滑权重退火 (Linear Weight Annealing) 策略. 通过动态调节惩罚强度 $\lambda(t)$, 训练过程更容易在预测损失与不变性惩罚之间取得相对平衡。

1.3.3 多尺度模型与分布偏移场景下的泛化验证

在工程实证层面, 本文基于标准的分布外 (OOD) 泛化任务构建了对比实验. 这些实验覆盖了从受控玩具数据到更复杂视觉场景, 再到 Qwen 平台上的文本 shortcut 设置, 用于检验低秩参数化、贝叶斯环境约束与快照保留机制结合后, 是否能够带来可观测的泛化-预算折中收益。

实验结果表明, 该框架在部分设置下能够以更低的训练成本接近全参数 BIRM 的过程最佳区间, 并在个别随机种子上达到更高局部峰值, 或在相近时间预算下达到更高峰值, 但其结论仍需结合具体任务、评估协议和随机种子稳定性来理解. 因而, 本文更希望把这些结果视为一种可复现的经验发现, 而不是对低秩因果学习的最终定论。

1.4 本文组织结构

第二章 预备知识与相关工作

本章旨在为后续 LoRA-BIRM 的方法设计与理论分析建立统一的概念基础。从全文的论证链条来看，第 2 章的任务不是简单罗列文献，而是回答三个前置问题：第一，为什么传统经验风险最小化在分布偏移下会失败，以及 IRM/BIRM 试图修复的究竟是什么；第二，为什么参数高效微调中的低秩结构不仅是工程压缩技巧，还可能成为因果学习中的结构性正则；第三，为什么一旦把贝叶斯推断与不变性约束同时带入大模型，就会立刻遭遇高维优化与计算复杂度问题。因此，本章按照“因果泛化基础 → 低秩参数化基础 → 变分推断与优化基础”的顺序组织内容，以便为第 3 章的 LoRA-BIRM 架构设计提供自然铺垫。

2.1 因果泛化基础：从 IRM 到 BIRM

2.1.1 IRM 的环境视角与基本目标

不变风险最小化 (Invariant Risk Minimization, IRM) 是因果表征学习领域的奠基性框架^[7]。传统的经验风险最小化 (ERM) 仅仅致力于最小化所有训练数据上的平均误差，极易收敛于依赖数据集中特定统计偏差的“捷径解”。为了提取跨域不变的因果特征，IRM 引入了“环境 (Environment)”的概念，将训练数据划分为多个来源于不同分布的子集。

IRM 的核心假设是：尽管不同环境中虚假特征与标签的关联强度可能剧烈波动，但真实的因果特征与标签之间的映射关系在所有环境中必须保持绝对恒定。基于此，IRM 在总体目标函数中引入了跨环境的一致性惩罚项 (Invariance Penalty)。这种惩罚强制要求网络学习到一种数据表征，使得在该表征之上构建的最优线性分类器能够在所有训练环境中同时达到最优（即各环境梯度的方差趋于零）。通过这种约束，IRM 理论上能够剥离环境中易变的虚假关联，从而实现分布外 (OOD) 的鲁棒泛化。

2.1.2 BIRM 的提出与坍缩修复

尽管 IRM 在浅层模型上取得了显著成功，但在面对更复杂的网络结构和更严苛的惩罚权重时，往往会陷入“特征坍缩 (Feature Collapse)”的困境。当目标函数中的方差惩罚项权重极大时，确定性的神经网络为了强行将各环境的差异降为零，倾向于直接遗忘所有提取到的特征，输出一个与输入无关的常数，导致模型的预测能力完全丧失^[9]。

为了缓解这一优化陷阱，Lin 等人提出了贝叶斯不变风险最小化 (Bayesian Invariant Risk Minimization, BIRM)^[9]。BIRM 摒弃了确定性的点估计，引入变分推断 (Variational Inference) 将网络权重建模为概率分布。通过在参数空间中注入不确定性噪声，BIRM 试图使模型在高惩罚权重下仍保留一定的探索能力，从而在因果特征学习与预测准确率之间取得更稳健的平衡。这一思路为后续讨论“贝叶斯化能否缓解 IRM 坍缩”提供了直接参照。

2.1.3 SparseIRM 与结构性容量瓶颈的启发

随着深度学习步入大模型时代, 研究者发现 IRM 框架在深层网络中存在一个内在的理论矛盾: 可训练性与泛化能力的对立^[16]. 现代神经网络通常需要过参数化 (Overparameterization) 来保证模型易于优化; 然而, Zhou 和 Lin 等人在后续研究中严谨地指出, 过参数化所引发的过拟合会轻易地摧毁 IRM 的不变性约束, 导致模型再次被高维的虚假特征所捕获^[16].

为了解决这一过参数化困境, 他们提出了稀疏不变风险最小化 (Sparse Invariant Risk Minimization, SparseIRM) 范式^[16]. SparseIRM 在训练过程中引入全局稀疏约束 (Global Sparsity Constraint), 通过限制模型的特征选择预算 (Feature Selection Budget), 减少模型利用高维虚假关联噪声进行插值的机会, 从而鼓励其选择低维且跨环境更稳定的特征^[16].

SparseIRM 的结果提示了“结构性容量瓶颈”在因果学习中的潜在价值. 然而, 全局稀疏化通常需要在全量参数图上进行掩码 (Mask) 计算或结构剪枝操作, 难以直接迁移至大语言模型 (LLM). 这一观察启发了本文的核心动机: 若“稀疏性 (Sparsity)”能够作为一种显式容量控制手段, 那么“低秩性 (Low-Rankness)”也可能以更易实现的方式提供类似的结构限制. 本文提出的 LoRA-BIRM 正是基于这一思路, 尝试以参数受限的低秩适配器替代更昂贵的全参数结构约束.

2.2 低秩参数化基础: 从 PEFT 到因果正则化

2.2.1 LoRA 的参数高效适配机制

随着大语言模型 (LLM) 与超大规模视觉模型的参数量呈指数级攀升, 传统的全参数微调 (Full-Parameter Fine-Tuning) 在显存占用与计算开销上已逐渐触及硬件极限. 为此, 学术界提出了一系列参数高效微调 (Parameter-Efficient Fine-Tuning, PEFT) 技术, 旨在仅更新极少部分参数的前提下, 达到与全参数微调相媲美的下游任务性能. 其中, 低秩适配 (Low-Rank Adaptation, LoRA) 凭借其出色的训练效率与无推理延迟的优势, 成为了当前主流的微调范式^[15].

LoRA 的核心思想基于一个重要的经验假设: 预训练模型在适配特定下游任务时, 其权重矩阵的内在更新量具有极低的本征维度 (Intrinsic Dimension). 具体而言, 对于预训练模型中一个尺寸为 $d_{in} \times d_{out}$ 的冻结权重矩阵 W_0 , LoRA 通过旁路注入两个可训练的低秩矩阵 $A \in \mathbb{R}^{r \times d_{in}}$ 与 $B \in \mathbb{R}^{d_{out} \times r}$ 来近似表示权重的更新量 ΔW , 其中秩 $r \ll \min(d_{in}, d_{out})$. 在前向传播过程中, 具有 LoRA 层的输出 h 可表示为:

$$h = W_0 x + \Delta W x = W_0 x + B A x. \quad (2.1)$$

为了确保在微调起始阶段 ($t = 0$) 不破坏模型原有的预训练表征, LoRA 采用了一种非对称的初始化策略: 对降维矩阵 A 采用随机高斯初始化, 而将升维矩阵 B 严格初始化为零矩阵. 这保证了初始时刻 $\Delta W = B A = 0$. 通过这种低秩分解, LoRA 能够将需要计算梯度的参数量压缩至原先的千分之一甚至更低, 极大地缓解了反向传播中的显存压力, 为将计算极其昂贵的变分推断 (Variational Inference) 引入大模型因果学习提供了物理上的可行性.

2.2.2 低秩约束为何能够抑制虚假特征

如前文所述, Zhou 等人提出的 SparseIRM 表明,“全局稀疏约束”可以通过限制特征选择预算来缓解因果学习中的过参数化问题^[16]. 顺着这一脉络, 本文进一步讨论: 稀疏性 (Sparsity) 与低秩性

(Low-Rankness) 都可以被看作约束模型复杂度的结构手段, 虽然二者并不等价, 但都可能通过减少可用自由度来削弱模型对高维虚假特征的依赖. 这也是本文尝试用 LoRA 替代更昂贵结构约束的主要动机.

从矩阵分解与优化的视角来看, 稀疏性关注的是矩阵在标准正交基 (即坐标轴) 下非零元素的个数, 对应于 L_0 或 L_1 范数惩罚; 而低秩性则关注矩阵在奇异值空间中非零奇异值的个数, 对应于核范数 (Nuclear Norm) 惩罚或显式的低秩参数化. 换言之, “低秩”本质上就是“奇异值频谱上的稀疏”.

在面对具有严重分布偏移的开放环境时, 虚假关联特征 (如图像背景、高频纹理) 通常张成了一个维度极高的非因果子空间 $\mathcal{Z}_{spu}$; 而真正的因果特征 (如物体形状轮廓) 则处于一个维度极低的因果子空间 $\mathcal{Z}_{inv}$ 中. 在全参数微调下, 权重矩阵拥有充裕的满秩自由度, 能够轻易在 $\mathcal{Z}_{spu}$ 中找到一条能够最小化经验风险的“捷径”, 从而导致泛化失败. SparseIRM 通过显式掩码 (Mask) 掐断了通向 $\mathcal{Z}_{spu}$ 的高维坐标连接; 而 LoRA 架构则通过将更新矩阵 ΔW 物理限制在极低的秩 r 上, 使得模型从根本上缺乏足够的谱空间 (Spectral Space) 去拟合且记忆高维的虚假噪声.

当我们在目标函数中施加强不变风险惩罚 (IRM Penalty) 时, LoRA 模型内部有限的低秩容量会受到更明显的“预算挤压 (Budget Squeeze)”. 在这种情况下, 优化器更难同时兼顾大量高维且跨环境波动剧烈的虚假特征, 因而更可能把有限的更新能力分配给低维且更稳定的方向. 因此, 低秩空间可以被理解作为一种“隐式正则化器 (Implicit Regularizer)”: 它不保证模型一定恢复因果子空间, 但确实为过滤虚假特征提供了一个计算上更友好的结构偏置.

2.3 变分推断与高维优化基础

2.3.1 ELBO 目标与重参数化技巧

在因果学习的贝叶斯扩展中, 计算参数的真实后验分布 $P(W|\mathcal{D})$ 通常是不可解的 (Intractable). 为此, 变分推断 (Variational Inference, VI) 引入了一个由参数 θ 控制的简单分布 $q_\theta(W)$ (如高斯分布) 来逼近真实的后验分布. 这一逼近过程在数学上等价于最大化证据下界 (Evidence Lower Bound, ELBO):

$$\mathcal{L}_{ELBO} = \mathbb{E}_{W \sim q_\theta} [\log P(\mathcal{D}|W)] - \text{KL}(q_\theta(W) || P(W)). \quad (2.2)$$

等式右侧的第一项为期望对数似然, 代表模型对数据的拟合与预测能力; 第二项为变分后验与先验分布之间的 KL 散度 (Kullback-Leibler Divergence), 充当正则化项.

为了允许梯度通过随机采样过程进行反向传播, Kingma 等人提出了著名的重参数化技巧 (Reparameterization Trick)^[17]. 该技巧将随机变量表示为确定性参数与无参数独立噪声的连续函数. 例如, 对于高斯分布 $q_\theta(W) = \mathcal{N}(\mu, \sigma^2)$, 我们可以将其重参数化为:

$$W = \mu + \sigma \odot \epsilon, \quad \text{其中 } \epsilon \sim \mathcal{N}(0, I). \quad (2.3)$$

通过这种变换, 损失函数关于均值 μ 与方差 σ 的期望梯度的无偏估计得以高效计算. 然而, 正如本文在第 1 章中所指出的, 当网络参数维度 d 极大时, 维持全量参数的均值与方差矩阵将带来极其庞大的显存开销, 且在每次迭代中生成 d 维的高斯噪声也是巨大的计算瓶颈.

2.3.2 高维因果优化的动力学困难

在深层神经网络中, 极高的参数维度不仅放大了计算复杂度, 更深刻地改变了损失景观 (Loss Landscape) 的拓扑结构. 当目标函数中存在强烈的正则化惩罚 (如 IRM 中的跨环境方差惩罚) 时, 优化器在高维空间中面临着极其复杂的动力学博弈.

具体而言, 经验风险的下降梯度与环境方差惩罚的下降梯度在高维流形上往往呈现出近乎正交甚至完全相反的方向. 在过参数化 (Overparameterization) 状态下, 模型拥有无数个能够使得经验风险最小化的局部极小值 (Local Minima). 然而, 面对极大的不变性惩罚权重 λ , 优化器为了以最陡峭的方向降低惩罚项, 极易陷入病态的平庸解 (Degenerate Solution)——即通过将所有特征权重 μ 衰减至接近于零, 从而换取方差惩罚项的绝对最小化 (因为常数输出的方差恒为零).

这种“梯度坍缩 (Gradient Collapse)”现象表明, 单纯依靠一阶优化算法很难在高维无约束空间中自发地寻找到既满足因果不变性、又保持极高预测能力的狭小“最优盆地 (Optimal Basin)”. 本文引入的低秩 (Low-Rank) 约束, 不仅在物理层面上极大地削减了需要维护的变分参数数量, 更是通过改变损失景观的曲率 (Curvature), 限制了模型走向平庸解的自由度. 这种将变分推断与低秩空间相融合的思路, 为突破高维因果优化的动力学困境提供了一条全新的理论通道.

2.4 本章小结

本章围绕 LoRA-BIRM 所依赖的三类基础知识完成了铺垫. 首先, 在因果泛化层面, 我们回顾了 IRM 如何通过环境不变性约束抵抗 shortcut, 以及 BIRM 与 SparseIRM 分别从贝叶斯不确定性和结构性容量限制两个方向修复 IRM 在深层网络中的失效. 其次, 在参数化层面, 我们说明了 LoRA 的低秩更新不仅是一种参数高效微调技术, 也能够数学上充当虚假特征过滤器. 最后, 在优化层面, 我们指出高维变分推断与强不变性惩罚的结合会带来显著的复杂度与动力学难题. 这些分析共同导向同一个结论: 若要让因果约束真正迁移到大模型平台, 就必须同时在**参数空间**与**优化目标**两端引入结构性改造. 这正是下一章提出 LoRA-BIRM 架构的直接出发点.

第三章 核心架构设计: LoRA-BIRM

本章详细阐述 LoRA-BIRM 的架构设计. 该方法以低秩适配 (LoRA) 为变分推断的参数化载体, 将贝叶斯不变风险最小化 (BIRM) 中的随机性限制在一个更小的参数子空间中实现, 以缓解全参数变分推断在大规模语言模型上的计算压力. 本章将依次介绍架构的计算解耦设计、优化动力学控制策略, 以及支撑实验的工具链实现细节.

3.1 架构设计思路与计算解耦

LoRA-BIRM 的核心设计哲学是**计算解耦**: 将预训练模型的确定性特征提取能力与因果不变性学习所需的随机性推断能力在物理层面上分离. 这一解耦首先是工程上的实现选择, 但同时也对应了一个更具体的问题: 在大模型微调中, 哪些参数值得承载不确定性, 哪些参数更适合保持冻结.

3.1.1 确定性骨干提取与随机性低秩采样

在标准的迁移学习范式中, 预训练语言模型的主干参数 $\mathbf{W}_0 \in \mathbb{R}^{d_{\text{out}} \times d_{\text{in}}}$ 被视为从海量语料中蒸馏出的通用语义知识, 其确定性是有保障的. 然而, 当模型需要在多个分布偏移的环境中学习因果不变特征时, 仅凭确定性的点估计参数无法对”哪些特征是真正因果的、哪些是虚假相关的”这一本质不确定性进行建模.

LoRA-BIRM 的解决方案是: **冻结骨干, 随机化低秩增量**. 具体而言, 对于预训练模型中的目标权重矩阵 $\mathbf{W}_0$, 其参数在整个训练过程中保持完全冻结, 仅通过一个低秩增量矩阵 $\Delta \mathbf{W}$ 进行任务适配:

$$\mathbf{W} = \mathbf{W}_0 + \Delta \mathbf{W} = \mathbf{W}_0 + \mathbf{B}\mathbf{A}, \quad (3.1)$$

其中 $\mathbf{A} \in \mathbb{R}^{r \times d_{\text{in}}}$, $\mathbf{B} \in \mathbb{R}^{d_{\text{out}} \times r}$, 秩 $r \ll \min(d_{\text{out}}, d_{\text{in}})$. 在标准 LoRA 中, $\mathbf{A}$ 和 $\mathbf{B}$ 均为确定性参数. 而在 LoRA-BIRM 中, 我们对低秩矩阵 $\mathbf{A}$ 施加变分贝叶斯处理, 将其建模为一个矩阵高斯分布:

$$\mathbf{A} \sim \mathcal{N}(\boldsymbol{\mu}_A, \text{diag}(\exp(\boldsymbol{\sigma}_A))), \quad (3.2)$$

其中 $\boldsymbol{\mu}_A$ 和 $\boldsymbol{\sigma}_A$ 均为可学习的参数矩阵, 分别代表低秩适配方向的均值与对数方差. 在每次前向传播中, 通过重参数化技巧 (Reparameterization Trick) 对 $\mathbf{A}$ 进行独立采样:

$$\mathbf{A} = \boldsymbol{\mu}_A + \boldsymbol{\epsilon} \odot \exp\left(\frac{1}{2}\boldsymbol{\sigma}_A\right), \quad \boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (3.3)$$

这一设计的直观含义是: 骨干网络的确定性前向传播负责提供语义特征表示, 而低秩子空间中的随机采样则负责在较小的参数范围内建模与任务相关的不确定性. 两者在计算图中相互配合, 但承担不同功能. 冻结骨干的另一个效果是**隐式正则化**: 低秩约束将变分参数的搜索空间从 $O(d_{\text{out}} \times d_{\text{in}})$ 压缩至 $O(r \times (d_{\text{out}} + d_{\text{in}}))$, 这一容量瓶颈 (Capacity Bottleneck) 减少了模型沿任意方向改写表示的自由度, 从而有助于降低对虚假相关性的过度记忆.

此外, 由于变分参数的维度从数十亿降至数百万量级, KL 散度的计算从原本的维度灾难变为可以高效精确计算的封闭形式:

$$D_{\text{KL}}(q(\mathbf{A})\|p(\mathbf{A})) = \frac{1}{2} \sum_{i,j} (\exp(\sigma_{A,ij}) + \mu_{A,ij}^2 - 1 - \sigma_{A,ij}), \quad (3.4)$$

其中先验 $p(\mathbf{A}) = \mathcal{N}(\mathbf{0}, \mathbf{I})$ 为标准高斯分布. 这一封闭形式的 KL 散度使得 ELBO 的优化无需蒙特卡洛近似, 从而减少了一类额外的采样噪声并提高了优化可控性.

3.1.2 联合损失函数重构与惩罚计算优化

LoRA-BIRM 的训练目标是一个多项惩罚的联合损失函数, 其设计综合了 BIRM 的变分 ELBO 框架与 IRM 的跨环境不变性约束. 设训练数据来自 K 个环境 $\{e_1, e_2, \dots, e_K\}$, 每个环境的经验风险为 $\mathcal{R}^{e_k}(\theta)$, 则完整的训练目标为:

$$\mathcal{L}_{\text{total}} = \underbrace{\frac{1}{K} \sum_{k=1}^K \mathcal{R}^{e_k}(\theta)}_{\text{NLL 项}} + \lambda(t) \cdot \underbrace{[\text{Var}_k(\mathcal{R}^{e_k}(\theta)) + \mathcal{P}_{\text{align}}]}_{\text{不变性惩罚项}} + \beta \cdot \underbrace{D_{\text{KL}}(q\|p)}_{\text{贝叶斯正则项}}, \quad (3.5)$$

其中各项的含义如下:

NLL 项为所有环境上的平均负对数似然, 驱动模型在所有训练分布上保持基本的预测能力.

不变性惩罚项由两部分构成. 第一部分 $\text{Var}_k(\mathcal{R}^{e_k})$ 为跨环境损失方差, 直接惩罚不同环境间的风险差异, 迫使模型寻找在所有环境上均衡的特征表示. 第二部分 $\mathcal{P}_{\text{align}}$ 为对齐惩罚 (Alignment Penalty), 用于度量同一批次内语义相似但环境标签不同的样本之间的预测一致性, 其计算方式为:

$$\mathcal{P}_{\text{align}} = \frac{1}{2} (|\mathcal{R}_{\text{spu}}^{e_1} - \mathcal{R}_{\text{env}}^{e_1}| + |\mathcal{R}_{\text{spu}}^{e_2} - \mathcal{R}_{\text{env}}^{e_2}|), \quad (3.6)$$

其中下标 spu 和 env 分别代表含有虚假相关性的样本子集与环境对照子集. 该项的引入使得模型不仅在宏观的环境级别上保持不变性, 还在微观的样本级别上对虚假特征的激活进行直接抑制.

贝叶斯正则项 $D_{\text{KL}}(q\|p)$ 为变分后验与先验之间的 KL 散度, 其作用是防止低秩适配矩阵的方差参数 σ_A 退化为零 (即退化为确定性的点估计), 从而维持模型对因果不确定性的持续建模能力. 超参数 β 控制贝叶斯正则化的强度, 在实验中设置为 $\beta = 10^{-4}$.

在实现层面, 为了避免 KL 散度随模型隐层维度 d_h 线性增长而导致的数值不稳定, 本文对 KL 项进行了维度归一化处理:

$$\tilde{D}_{\text{KL}} = \frac{D_{\text{KL}}(q\|p)}{d_h}, \quad (3.7)$$

这一归一化确保了 KL 惩罚的量级在不同规模的模型上保持一致, 使得超参数 β 具有跨模型的可迁移性.

3.2 优化动力学控制：平滑权重退火机制

不变性惩罚权重 $\lambda(t)$ 的调度策略对 LoRA-BIRM 的训练稳定性具有决定性影响. 本节首先分析固定高惩罚权重导致的“休克疗法”缺陷, 随后介绍本文采用的线性动态退火策略.

3.2.1 传统固定惩罚权重下的休克疗法缺陷

在 IRM 及其早期变体的实现中, 不变性惩罚权重 λ 通常被设置为一个固定的大常数 (如 $\lambda = 100$ 或 $\lambda = 1000$). 这种“一步到位”的策略在理论上具有吸引力——更强的惩罚应当更快地迫使模型收敛至不变特征子空间. 然而, 在实践中, 这种“休克疗法”往往导致严重的**梯度坍塌 (Gradient Collapse)** 现象.

其根本原因在于优化初期的梯度竞争. 在训练开始阶段, 模型参数处于随机初始化状态, 不同环境的损失值差异极大, 导致方差惩罚项 $\text{Var}_k(\mathcal{R}^{e_k})$ 的梯度量级远超 NLL 项的梯度量级. 当 λ 过大时, 优化器的更新方向几乎完全由惩罚项主导. 为了以最快速度降低跨环境方差, 最简单的策略是将所有特征权重压缩至零——因为常数预测的方差恒为零. 这一病态解 (Degenerate Solution) 在数学上满足不变性约束, 但在语义上毫无意义.

在贝叶斯框架下, 梯度坍塌还会引发额外的连锁反应: 当均值参数 μ_A 被压缩至零时, KL 散度的梯度会进一步推动方差参数 σ_A 向先验收缩, 导致模型完全丧失对任务特征的适配能力. 这种“双重坍塌”在实验中表现为训练损失在极少数步骤内骤降至接近随机猜测水平, 且无法通过后续训练恢复.

3.2.2 线性动态退火策略 (Linear Annealing) 的设计

为克服上述缺陷, 本文设计了一种**线性动态退火 (Linear Annealing)** 策略, 其核心思想是: 在训练初期给予模型充分的“热身”时间, 让 NLL 项主导优化方向, 使模型首先建立起对任务的基本理解; 随后逐步引入不变性惩罚, 在已有特征表示的基础上温和地施加因果约束.

具体地, 惩罚权重 $\lambda(t)$ 按照如下分段线性函数随训练步数 t 动态调整:

$$\lambda(t) = \begin{cases} \lambda_{\text{peak}} \cdot \frac{t}{T_{\text{warm}}}, & t \leq T_{\text{warm}}, \\ \lambda_{\text{peak}}, & t > T_{\text{warm}}, \end{cases} \quad (3.8)$$

其中 λ_{peak} 为目标峰值惩罚权重, T_{warm} 为预热步数. 在本文的实验设置中, $\lambda_{\text{peak}} = 10.0$, $T_{\text{warm}} = T_{\text{total}}/3$, 即将总训练步数的前三分之一用于惩罚权重的线性爬升.

这一设计的理论依据来自于对损失景观的分析. 在预热阶段 $t \leq T_{\text{warm}}$, 较小的 $\lambda(t)$ 使得 NLL 梯度占主导, 模型在参数空间中首先找到一个具有合理预测能力的区域. 此时损失景观中的 NLL 极小值盆地 (Basin) 已经形成, 为后续的惩罚引入提供了稳定的“锚点”. 在惩罚爬升阶段, 逐渐增大的 $\lambda(t)$ 温和地将优化轨迹从 NLL 极小值盆地引导至满足不变性约束的更优区域, 而不会因为惩罚梯度的突然主导而导致参数的剧烈震荡.

与余弦退火 (Cosine Annealing) 或指数退火等非线性调度相比, 线性退火具有两个显著优势: 其一, 惩罚增长速率恒定, 避免了非线性调度在某些阶段增长过快而在另一些阶段增长过慢的问题; 其二, 线性调度仅有两个超参数 (λ_{peak} 和 T_{warm}), 调参成本极低, 且对超参数的敏感性较弱.

此外, 本文还引入了**指数移动平均 (EMA, Exponential Moving Average)** 机制作为训练稳定性的辅助保障. 在每个训练步骤结束后, 维护一个 EMA 模型参数 θ_{ema} :

$$\theta_{\text{ema}} \leftarrow \alpha \cdot \theta_{\text{ema}} + (1 - \alpha) \cdot \theta, \quad (3.9)$$

其中衰减系数 $\alpha = 0.92$. EMA 模型通过对历史参数的加权平均, 有效平滑了训练过程中因惩罚权重变化引起的参数震荡, 使得模型在验证集上的性能曲线更加平稳. 在每个检查点 (Checkpoint) 处,

同时对当前模型和 EMA 模型进行完整的验证集评估, 并保留历史最优快照 (Best Snapshot) 作为最终模型, 以应对复杂场景下训练后期可能出现的性能回退问题。

3.3 工具链与代码库建立

为支撑上述架构设计的实验验证, 本文基于 PyTorch 和 HuggingFace PEFT 库构建了一套完整的 LoRA-BIRM 实验工具链。本节介绍其中两个关键的工程实现细节。

3.3.1 贝叶斯 LoRA 分类头的参数化构建

LoRA-BIRM 的变分推断核心被封装在一个独立的 `BIRMLightweightHead` 模块中。该模块接收预训练模型最后一层的隐层表示 $\mathbf{h} \in \mathbb{R}^{d_h}$ 作为输入, 并通过贝叶斯线性层输出分类 logits。其参数化结构如下:

- **均值参数** $\mu_W \in \mathbb{R}^{C \times d_h}$: 分类权重矩阵的均值, 其中 C 为类别数。
- **对数方差参数** $\sigma_W \in \mathbb{R}^{C \times d_h}$: 分类权重矩阵的对数方差, 初始化为 -3 以确保训练初期的方差较小, 避免过大的随机性干扰 NLL 的优化。
- **方差截断**: 为防止数值溢出, 对数方差被截断至区间 $[-8, 0]$, 对应方差范围 $[e^{-8}, 1]$ 。

在每次前向传播中, 通过重参数化技巧对权重矩阵进行独立采样:

$$\mathbf{W} = \mu_W + \epsilon \odot \exp\left(\frac{1}{2}\text{clamp}(\sigma_W, -8, 0)\right), \quad \epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I}). \quad (3.10)$$

值得注意的是, 每次前向传播均进行**独立采样**, 而非在整个 mini-batch 内共享同一个噪声样本。这一设计确保了不同样本的预测之间具有独立的随机性, 使得跨环境方差惩罚的估计更加准确, 避免了批内噪声相关性对惩罚梯度的污染。

在推断阶段, 为获得确定性的预测结果, 直接使用均值参数 μ_W 进行前向传播, 不进行随机采样。这一“均值推断”策略在理论上对应于变分后验的众数估计, 在实践中被证明比蒙特卡洛平均具有更低的方差和更高的计算效率。

3.3.2 差分学习率与全量分批测试逻辑注入

差分学习率 (Differential Learning Rate) 是 LoRA-BIRM 训练策略的重要组成部分。由于贝叶斯分类头的参数从随机初始化开始训练, 而 LoRA 适配层的参数则在预训练权重的基础上进行微调, 两者所需的学习率量级存在显著差异。本文采用如下差分学习率配置:

- **贝叶斯分类头**: 学习率 $\eta_{\text{head}} = 3 \times 10^{-4}$, 较高的学习率使得分类头能够快速适应任务。
- **LoRA 适配层**: 学习率 $\eta_{\text{LoRA}} = 5 \times 10^{-5}$, 较低的学习率保护预训练知识不被过度覆盖。

两组参数通过 PyTorch 优化器的参数组 (Parameter Group) 机制分别配置, 共享同一个 AdamW 优化器实例, 以确保动量 (Momentum) 和自适应学习率的统计量在两组参数间独立维护。

全量分批测试逻辑 (Full-Batch Evaluation) 是保证模型选择可靠性的关键工程细节。在早期实现中, 为节省验证时间, 每个检查点仅在验证集的随机子集 (约 200 个样本) 上进行评估。然而,

这种近似评估引入了显著的噪声: 由于 LoRA-BIRM 的预测具有随机性 (每次前向传播均进行独立采样), 小样本评估的准确率估计方差极大, 导致模型选择基于噪声信号而非真实性能. 在极端情况下, 一个在完整验证集上准确率仅为 51% 的模型, 可能因为恰好在某个小批次上表现良好而被错误地选为最优快照.

为彻底消除这一问题, 本文在每个检查点处对**完整验证集**进行评估, 并在评估阶段切换至均值推断模式 (关闭随机采样). 这一”全量确定性评估”策略确保了模型选择信号的可靠性, 是后续比较不同 LoRA-BIRM 变体时保证结论不过度受评估噪声干扰的重要工程前提.

为方便复现实验, 本文已将 CMNIST、Spurious CIFAR 与 Qwen 平台上的核心脚本、训练配置以及轻量结果摘要统一整理至 GitHub 仓库 https://github.com/sunlay01/lora_birm. 其中, Qwen 相关代码位于仓库的 `qwen/` 目录下, 包括 ERM、IRMv1、BIRM 与 LoRA-BIRM Snapshot 的主要训练脚本以及对应的结果汇总文件.

第四章 理论动机与规模分析：从 IRM/BIRM 到低秩参数化

本章的目标不是为 LoRA-BIRM 建立一套全新的完备理论，也不声称低秩化本身就足以保证模型恢复因果表征。更实际的目标有三点：第一，回顾 IRM 在线性总体模型下已经成立的可识别性结果；第二，说明这些结果在有限样本、过参数化网络与贝叶斯微调场景中为何会明显变弱；第三，从参数自由度与 KL 项缩放两个角度解释，为什么将可训练随机性限制在低维子空间内是一个合理的工程化选择。因此，本章同时包含文献中的已知结论与本文的量级分析和方法动机；后者主要用于解释实验现象，不应被理解为严格的泛化保证。

4.1 本文后续采用的 LoRA-BIRM 标准化定义

4.1.1 标准化定义

在进入具体分析之前，有必要先把本文后续所称的 LoRA-BIRM 固定为一个统一对象。原因在于，后续实验章节在具体实现上存在差异：有的版本把随机性施加在低秩增量上，有的版本只对低秩路径配套的轻量头部做贝叶斯化，环境惩罚项的具体写法也有所不同。若不先给出统一定义，理论讨论就容易在不同实现之间来回切换。

定义 4.1 (本文后续采用的 LoRA-BIRM 标准化定义)。本文在理论章节中将 LoRA-BIRM 统一定义为如下训练模板：

$$W = W_0 + \Delta W, \quad \Delta W = BA, \quad (4.1)$$

其中冻结骨干参数 $W_0 \in \mathbb{R}^{d_{out} \times d_{in}}$ ，低秩增量由

$$A \in \mathbb{R}^{r \times d_{in}}, \quad B \in \mathbb{R}^{d_{out} \times r}, \quad r \ll \min(d_{in}, d_{out}) \quad (4.2)$$

给出。记 Θ_{bayes} 为一个小参数集合，它可以是低秩增量本身，也可以是低秩路径配套的轻量头部，或二者的并集。在 Θ_{bayes} 上引入变分后验 $q_\phi(\Theta_{\text{bayes}})$ 与先验 $p(\Theta_{\text{bayes}})$ ，并在多环境训练集上优化

$$\mathcal{L}_{\text{LB}} = \frac{1}{|\mathcal{E}|} \sum_{e \in \mathcal{E}} \mathcal{R}^e + \lambda \mathcal{P}_{\text{inv}} + \beta \text{KL}(q_\phi(\Theta_{\text{bayes}}) \| p(\Theta_{\text{bayes}})), \quad (4.3)$$

其中 $\mathcal{R}^e$ 表示环境 e 上的经验风险， $\mathcal{P}_{\text{inv}}$ 表示某种环境一致性惩罚，例如环境风险方差、梯度一致性惩罚或其变体。

定义 4.1 的作用，不是掩盖实验实现差异，而是把这些差异放到一个共同模板之下。换言之，本文后续提到的具体 Route、Snapshot 或 Qwen 版本，都被视为这一标准化定义在 Θ_{bayes} 、 $\mathcal{P}_{\text{inv}}$ 与模型选择机制上的不同实例。理论部分只讨论这类实例共享的结构性质，不逐一为每个实现建立单独理论。

4.2 IRM 的线性理论背景与有限样本偏离

4.2.1 线性一般位置假设与可识别性结果

IRM 的经典理论结果建立在线性结构方程模型 (Linear SEM) 之上. 设输入特征 $X \in \mathbb{R}^d$ 可分解为真实的因果特征 $X_{inv} \in \mathbb{R}^{d_{inv}}$ 与虚假特征 $X_{spu} \in \mathbb{R}^{d_s}$, 其中 $d = d_{inv} + d_s$. 设所有环境 $e \in \mathcal{E}_{all}$ 共享同一个因果机制

$$Y = \gamma^\top X_{inv} + \epsilon^e, \quad (4.4)$$

并记 $\Sigma^e = \mathbb{E}[XX^\top]$ 为环境 e 下的特征协方差矩阵.

定义 4.2 (线性一般位置 (Linear General Position) ^[7]). 如果对于任意非零向量 $v \in \mathbb{R}^d$, 向量组 $\{\Sigma^e v\}_{e \in \mathcal{E}_{tr}}$ 能够张成一个维度至少为 r 的线性子空间, 则称训练环境集合 $\mathcal{E}_{tr}$ 处于度数为 r 的线性一般位置.

该定义的直观意义是: 不同环境必须在足够多的方向上提供差异化扰动, 否则虚假特征就可能与因果特征一起被模型吸收, 从而无法被不变性约束区分开来.

定理 4.3 (IRM 线性表征可识别性, 摘自 ^[7]). 假设训练环境集合 $\mathcal{E}_{tr}$ 处于度数为 r 的线性一般位置, 且训练环境数量满足

$$|\mathcal{E}_{tr}| > d - d_{inv} + \frac{d_{inv}}{r}. \quad (4.5)$$

那么对于任意满足不变性约束 $\nabla_{w|w=w^*} \mathcal{R}^e(w\Phi) = 0$, $\forall e \in \mathcal{E}_{tr}$ 的线性表征 Φ , 存在可逆线性变换 S , 使得

$$\Phi X = S X_{inv}. \quad (4.6)$$

该定理说明: 在线性、总体分布且环境足够丰富的设定下, IRM 的确可能把表征限制到因果子空间中. 这是 IRM 最核心的理论吸引力. 但同样需要强调, 这一结果依赖强假设: 线性模型、总体协方差、精确环境划分以及充分多的训练环境. 它为方法提供了理论起点, 但并不直接覆盖深度网络的有限样本微调场景.

4.2.2 这些结果的适用范围

除可识别性之外, 原始 IRM 理论还给出了一个测度论层面的补充结论: 在适当的矩阵空间中, 不满足“线性一般位置”的协方差元组构成一个测度为零的集合 ^[7]. 这意味着在线性总体模型里, 一般位置并不是一个纯粹人为构造的病态假设; 对“随机扰动足够丰富”的环境而言, 它在几何上是可期待的.

不过, 这一补充结论的作用也应被谨慎理解. 它说明的是总体协方差层面的 generic 性质, 不是对现实训练过程的直接保证. 一旦进入有限样本、非线性表征、环境数目有限以及优化器存在偏置的场景, 原本在线性总体模型下成立的识别结论就会明显变弱. 因而, 对本文所关心的大模型微调任务而言, 更合理的做法不是把这些线性定理直接当作“已有答案”, 而是把它们当作理解不变性目标的背景框架.

4.2.3 有限样本与过参数化下的插值问题

Lin 等人^[9]与 Zhou 等人^[16]强调, 当模型进入有限样本且高度过参数化的 regime 时, 训练集上往往存在大量插值解, 这会削弱 IRM 惩罚对“因果解”和“记忆解”的区分能力. 用线性代数的语言来说, 若模型有效参数维度显著大于总样本量, 经验风险优化问题可能退化为欠定系统.

命题 4.4 (有限样本下插值解的存在性, 表述整理自^[9,16]). 设总训练样本量为 $n = \sum_e n_e$. 当模型有效参数维度显著大于 n 时, 经验风险最小化问题通常存在训练损失为零的插值解. 这些解未必对应真实因果机制, 但会使基于训练环境风险或梯度一致性的约束失去一部分区分力.

证明思路并不复杂: 在线性欠定系统中, 可通过伪逆或其他插值构造使训练样本被完全拟合. 一旦每个环境上的经验风险都接近于零, 许多依赖训练环境损失差异的惩罚项也会同步缩小. 因此, 即使总体分布层面的可识别性结果成立, 它也不能自动迁移到有限样本、深层过参数化网络的实际训练中.

4.3 BIRM 的理论动机与参数维度问题

4.3.1 过拟合区域与 IRM/IRMv1 的退化现象

在上述背景下, BIRM 的文献首先关心的是: 为什么确定性的 IRM/IRMv1 在有限样本深度模型里容易退化为“谁能把训练集拟合到零, 谁就赢”的状态. Lin 等人^[9]引入了如下定义:

定义 4.5 (过拟合区域 (Overfitting Region)^[9]). 假设训练环境与样本数量有限, 且特征提取器参数 u 与分类器参数 w 具有足够容量来完全拟合训练数据. 定义

$$\Omega := \{(\bar{w}, \bar{u}) \mid \mathcal{R}^e(\bar{w}, \bar{u}) = 0, \forall e \in \mathcal{E}_{tr}\}, \quad (4.7)$$

其中 $\mathcal{R}^e$ 表示环境 e 上的非负经验风险.

命题 4.6 (一般 IRM 在过拟合区域中的退化, 摘自^[9]). 在有限样本与充足容量的假设下, 过拟合区域 Ω 中的元素不会被一般 IRM 目标排除; 换言之, 一旦模型能把每个环境的经验风险都压到零, IRM 约束本身不再足以区分这些解的泛化质量.

其核心原因是: 对任意 $(\bar{w}, \bar{u}) \in \Omega$, 经验风险已经达到非负损失的全局最小值 0. 在这种情况下, IRM 的“各环境共享同一个最优分类器”约束会被零风险解自动满足. 因而, 该命题的意义不是说 IRM 在所有任务上都会失败, 而是指出仅靠训练环境上的确定性不变性约束, 并不能从原理上排除记忆型插值解.

定理 4.7 (IRMv1 在过拟合区域中的退化, 摘自^[9]). 若 $\mathcal{R}^e(w, u)$ 关于参数可微, 则对任意 $(\bar{w}, \bar{u}) \in \Omega$, 有

$$(\bar{w}, \bar{u}) \in \arg \min_{w, u} \sum_{e \in \mathcal{E}_{tr}} \mathcal{R}^e(w, u) + \lambda \|\nabla_w \mathcal{R}^e(w, u)\|^2. \quad (4.8)$$

这里的推理同样直接: 在可微非负损失中, 经验风险为零意味着该点关于 w 的梯度也为零, 因而 IRMv1 的梯度惩罚项同步消失. 这说明 IRMv1 的一阶惩罚在高容量模型中也可能失去约束力.

4.3.2 BIRM 为何可能缓解退化

为缓解上述确定性退化, BIRM 放弃了对分类器参数 w 的点估计, 转而学习其变分后验分布 $q_u(w)$ ^[9]. 若先验分布记为 $p_0(w)$, 对应的 ELBO 目标可写为

$$\max_{q_u} \sum_e \mathbb{E}_{q_u}[-\mathcal{R}^e(w, u)] - \text{KL}(q_u(w) \| p_0(w)). \quad (4.9)$$

与确定性 IRM 相比, 这里的关键变化不是“贝叶斯一定更强”, 而是模型不再只在单个点估计上满足不变性约束, 而是在一个带有不确定性的后验邻域内平衡经验风险与复杂度惩罚. 这种处理为避免早期塌缩提供了额外缓冲: 即便某个点估计解在训练集上已经达到零风险, 后验分布是否过于尖锐、是否与先验偏离过大, 仍会受到 KL 项和环境惩罚的共同约束. 这正是 BIRM 的理论动机.

当然, 这一步也不应被说得过头. BIRM 提供的是一种更稳健的参数化视角, 而不是对所有任务都成立的严格最优性结论. 它能否真正优于确定性 IRM, 仍取决于后验族、优化算法、环境划分方式以及模型规模.

4.3.3 大模型场景下 KL 项的规模增长

当 BIRM 被直接迁移到大模型时, 一个自然问题是变分正则项的量级. 若采用平均场高斯近似,

$$p_0(w) = \mathcal{N}(\mathbf{0}, I_d), \quad q_u(w) = \mathcal{N}(\mu, \text{diag}(\sigma^2)), \quad (4.10)$$

则 KL 散度可写为

$$\text{KL}(q_u \| p_0) = \frac{1}{2} \sum_{i=1}^d (\mu_i^2 + \sigma_i^2 - \log \sigma_i^2 - 1). \quad (4.11)$$

这个表达式本身并不意味着“大模型一定无法训练”, 但它清楚地说明了一个量级事实: 只要有相当比例的参数维度发生均值偏移或方差收缩, KL 惩罚就会按参数维度 d 逐项累加. 因而, 在全参数变分微调中, KL 项的总量级通常与模型参数规模线性相关.

这一点会带来两个后果. 第一, 在常见的 PAC-Bayesian 界中, 复杂度项依赖于 $\sqrt{\text{KL}/N}$, 因而当 KL 随 d 快速增长时, 泛化上界会迅速变松. 第二, 在实际优化中, 若 KL 权重未被仔细校准, 它可能过早地主导梯度, 使后验分布更倾向于停留在接近先验的位置, 从而削弱经验风险和环境惩罚对表示学习的作用.

因此, 对大模型而言, BIRM 真正面临的问题不只是“是否要做贝叶斯化”, 还包括“应把随机性施加在多大的参数子空间上”. 这正好为低秩参数化提供了介入位置.

4.4 低秩参数化的作用: 容量控制与复杂度缩放

上两节的文献结论给出了两个信号: 一方面, 有限样本和过参数化会削弱 IRM 惩罚的辨别力; 另一方面, 若把变分后验直接施加到全部参数上, KL 项又会随模型规模变得越来越难控制. 这些结论并不自动推出 LoRA-BIRM 就是正确答案, 但它们解释了为什么“限制可训练随机性所在的子空间”是值得尝试的方向.

4.4.1 低秩更新带来的有效自由度收缩

设某一层预训练权重为 $W_0 \in \mathbb{R}^{d_{out} \times d_{in}}$, LoRA 采用

$$W = W_0 + BA, \quad (4.12)$$

其中 $A \in \mathbb{R}^{r \times d_{in}}$, $B \in \mathbb{R}^{d_{out} \times r}$, 且 $r \ll \min(d_{in}, d_{out})$. 从参数个数的角度看, 低秩更新涉及的可训练参数量满足上界

$$D_{\text{LoRA}} \leq r(d_{in} + d_{out}). \quad (4.13)$$

命题 4.8 (秩- r 更新的有效自由度). 设

$$\mathcal{M}_r := \{\Delta W \in \mathbb{R}^{d_{out} \times d_{in}} \mid \text{rank}(\Delta W) = r\}. \quad (4.14)$$

若 $A \in \mathbb{R}^{r \times d_{in}}$ 满足满行秩, $B \in \mathbb{R}^{d_{out} \times r}$ 满足满列秩, 且 $\Delta W = BA$, 则秩- r 矩阵流形 $\mathcal{M}_r$ 的维度为

$$\dim(\mathcal{M}_r) = r(d_{in} + d_{out} - r). \quad (4.15)$$

因此, LoRA 路径虽然以 $r(d_{in} + d_{out})$ 个标量进行参数化, 但其对应的有效自由度可以理解为至多 $r(d_{in} + d_{out} - r)$.

证明. 分解 $\Delta W = BA$ 使用了 $rd_{in} + rd_{out}$ 个标量参数. 但这一分解并不唯一: 对任意可逆矩阵 $C \in \text{GL}(r)$, 都有

$$BA = (BC)(C^{-1}A). \quad (4.16)$$

因此, 参数化中存在一个由 $\text{GL}(r)$ 诱导的等价类, 其维度为 r^2 . 从而秩- r 矩阵流形的自由度为

$$rd_{in} + rd_{out} - r^2 = r(d_{in} + d_{out} - r). \quad (4.17)$$

证毕. □

命题 4.8 的意义在于, 它把“低秩更新限制了搜索空间”这一直觉写成了一个清楚的数量级结果. 当 r 很小时, $r(d_{in} + d_{out} - r)$ 与全参数矩阵的自由度 $d_{in}d_{out}$ 相比通常小得多. 这并不自动推出泛化更好, 但至少说明 LoRA 更新无法像全参数微调那样沿任意方向自由改写表示.

第一, 低秩更新降低了模型改写预训练表示的自由度. 这不意味着模型必然无法记忆虚假相关, 但意味着它更难在每一层都沿任意方向同时拟合环境特有噪声. 第二, 在冻结骨干的设定下, 低秩路径更像是对已有高层表示做有限方向的重排. 这种结构偏置与“寻找少数跨环境稳定方向”的目标是相容的, 也与本文实验中观察到的较快搜索和较小训练开销相一致.

因此, 本文对低秩性的使用不应被理解为“它在数学上保证了因果恢复”, 而应理解为一种容量控制手段: 它通过压缩可训练子空间, 让模型更难完全依赖高维捷径, 同时使环境惩罚更有机会发挥作用.

4.4.2 只在小参数子空间上做变分推断时的 KL 缩放

理论上, 更关键的变化发生在贝叶斯参数的规模上. 本文不同实验实现的共同点, 不是对整个底座做全参数贝叶斯化, 而是把随机性限制在一个远小于全参数空间的参数集合 Θ_{bayes} 上. 这个集合可以是低秩增量本身, 也可以是与低秩路径配套的轻量头部; 只要其规模远小于全模型参数量, 下面的量级分析就成立.

命题 4.9 (小参数子空间上的 KL 缩放). 设 $\Theta_{\text{bayes}} = (\theta_1, \dots, \theta_m)$, 且在该参数集合上采用因子化后验与先验

$$q(\Theta_{\text{bayes}}) = \prod_{i=1}^m q_i(\theta_i), \quad p(\Theta_{\text{bayes}}) = \prod_{i=1}^m p_i(\theta_i). \quad (4.18)$$

若存在常数 $C > 0$ 使得对所有 i 都有 $\text{KL}(q_i \| p_i) \leq C$, 则

$$\text{KL}(q(\Theta_{\text{bayes}}) \| p(\Theta_{\text{bayes}})) \leq Cm = \mathcal{O}(m). \quad (4.19)$$

进一步地, 若 Θ_{bayes} 仅覆盖秩- r 低秩更新, 则 m 至少在量级上由 $r(d_{\text{in}} + d_{\text{out}})$ 控制; 若按命题 4.8 只看有效自由度, 则其规模可进一步理解为不超过 $r(d_{\text{in}} + d_{\text{out}} - r)$.

证明. 在独立分解假设下, KL 散度具有可加性, 因而

$$\text{KL}(q(\Theta_{\text{bayes}}) \| p(\Theta_{\text{bayes}})) = \sum_{i=1}^{|\Theta_{\text{bayes}}|} \text{KL}(q_i \| p_i) \leq \sum_{i=1}^m C = Cm. \quad (4.20)$$

证毕. □

命题 4.9 说明, 只要贝叶斯化发生在一个足够小的参数集合上, KL 项的规模就会首先受该集合的维度控制, 而不是直接受全模型参数量控制. 这也是为什么在大模型场景下, “先限制贝叶斯参数所在子空间, 再做变分推断”比“先全参数贝叶斯化, 再靠调参压缩 KL”更像一个可执行的策略.

当 Θ_{bayes} 仅覆盖低秩增量时, 常见情形下有

$$|\Theta_{\text{bayes}}| = \mathcal{O}(r(d_{\text{in}} + d_{\text{out}})), \quad (4.21)$$

于是 KL 项的规模也会从全参数情况下的 $\mathcal{O}(d_{\text{in}}d_{\text{out}})$ 下降到与低秩参数量同阶. 若再把这一量级代入常见的复杂度项 $\sqrt{\text{KL}/N}$, 可以得到一个更温和的缩放关系:

$$\sqrt{\frac{\text{KL}}{N}} \rightsquigarrow \mathcal{O}\left(\sqrt{\frac{r(d_{\text{in}} + d_{\text{out}})}{N}}\right). \quad (4.22)$$

这里仍需强调, 这只是量级分析, 不是 tight 的泛化定理. 它不能保证低秩贝叶斯方法一定优于全参数方法, 但它提供了一个相当直接的解释: 当随机性只施加在一个小得多的参数子空间中时, KL 正则更容易与经验风险项处于同一数量级, 从而减少“惩罚过强导致训练几乎不动”的风险.

4.5 本章不声称的内容

为了避免理论章节再次被理解得过满, 有必要明确指出本章不声称以下三点.

第一, 本章并没有证明 LoRA-BIRM 在有限样本的深层非线性网络中必然恢复真实因果空间. 现有分析最多说明: 与全参数不变性训练相比, 低秩参数化与小参数子空间贝叶斯化在规模上更可控, 因而是一个合理的工程化近似.

第二, 本章并没有证明低秩性与稀疏性在数学上等价, 也没有证明 LoRA 一定优于 SparseIRM 或全参数 BIRM. 本文只把它们都看作“结构性容量控制”的不同实现, 并据此提出方法动机.

第三, 本章没有把退火、EMA、快照选择等策略当作泛化理论的一部分. 这些机制在本文中主要承担优化稳定与模型选择的角色, 它们是否有效仍需要通过实验协议单独检验.

4.6 本章小结

本章并没有试图证明 LoRA-BIRM 必然恢复因果特征, 而是建立了一个更保守但更可信的理论叙事. 一方面, IRM 在线性总体模型下有明确的可识别性背景; 另一方面, 这些结果在有限样本和过参数化网络中会明显变弱, BIRM 则通过后验不确定性为缓解退化提供了一种思路. 当模型规模继续增大时, 全参数变分推断又会带来 KL 项随维度累积的问题. 在这一背景下, 低秩参数化的价值主要体现为两点: 它压缩了可训练自由度, 也压缩了需要贝叶斯化的参数规模. 因而, 本文后续方法更适合被理解作为一种**受理论动机启发的工程化近似**: 它并未解决因果泛化的全部理论难题, 但为“大模型上的不变性约束如何落地”提供了一个相对自洽的折中方案.

第五章 核心机理仿真与验证 (基于 Colored MNIST)

本章的论证遵循“先验证方法是否成立, 再说明其收益边界”的顺序展开. 具体而言, 我们先在 CMNIST 上介绍任务构造与四类对比方法, 随后集中报告 Route A/Route B 与全参数基线的 OOD 结果、代价趋势和机制差异, 最后明确指出 CMNIST 只能回答“方法是否成立”, 还不能回答“方法是否已经在复杂场景中站稳”. 这样的安排也为下一章进入 Spurious CIFAR 做好铺垫.

5.1 实验设置与对比方法

5.1.1 因果视觉任务定义: 引入虚假颜色的 CMNIST

为了验证本文提出的低秩贝叶斯因果学习框架是否能够在最小可控场景下稳定工作, 本章首先选取 Colored MNIST (CMNIST) 作为核心机理验证平台. 选择该任务的原因在于: 其分布偏移由一个可解释、可精确操控的虚假特征所主导, 因而非常适合用于检验模型是否真正学到了跨环境不变的判别机制, 而不是继续依赖环境特有的统计捷径.

本文沿用经典二分类构造方式, 将原始 MNIST 数字按照“是否小于 5”映射为二元标签, 并进一步引入 25% 的标签扰动. 在此基础上, 每个样本被复制为两个颜色通道并仅保留其中一个通道, 从而使颜色成为显式的虚假特征. 训练阶段构造两个环境, 其颜色翻转概率分别设为 $e = 0.2$ 与 $e = 0.1$, 因而颜色与标签仍保持较强相关; 测试阶段构造一个更强的反转环境, 令 $e = 0.9$, 即颜色与标签的相关方向几乎完全颠倒. 在这种设置下, 一个过度依赖颜色线索的模型将在训练环境中获得看似良好的经验风险, 但在测试环境中发生明显退化.

图 5.1 给出了本实验中三类环境的样本示意. 可以看到, 训练环境中的颜色偏置高度稳定, 而测试环境则刻意打破这种稳定性. 因此, 该任务本质上是在检验模型能否越过“颜色”这一捷径, 转而依赖数字形状这一跨环境不变特征.

5.1.2 四种方法的训练方式与评估协议

为了尽可能公平地评估本文方法的有效性, 我们在同一份 CMNIST 数据划分上比较以下四类方法, 并统一使用训练环境外测试集上的 OOD 准确率作为核心指标:

- **IRMv1**: 采用确定性多层感知机作为主干, 通过环境加权嵌入 (EBD) 计算 IRM 一阶梯度惩罚, 作为经典不变风险最小化基线.
- **Full-BIRM (Official)**: 保持与官方思路一致的全参数确定性骨干网络, 并在环境权重上施加蒙特卡洛采样后的贝叶斯不变性惩罚, 作为全参数 BIRM 基线.
- **LoRA-BIRM (Route A)**: 保持官方 EBD 惩罚逻辑不变, 仅将主干网络替换为确定性 LoRA 适配形式, 用于检验“低秩参数化”本身是否足以带来提升.



图 5.1: CMNIST 三类环境的样本可视化. 前两个环境用于训练, 第三个环境用于分布外测试.

- **LoRA-BIRM (Route B):** 采用真实的低秩变分推断路径, 在 LoRA 子空间中进行随机采样与环境方差惩罚, 是本文主张的核心实现路线.

四种方法虽然训练目标不同, 但训练协议保持一致: 都在相同的两环境 CMNIST 训练集上进行优化, 都以数字形状作为潜在因果特征、颜色作为显式虚假特征, 并在统一的反转测试环境上评估泛化能力. IRMv1 与 Full-BIRM 共享相同的全参数 MLP 主干; LoRA 两条路线则使用相同秩设置的低秩适配器, 区别只在于是否真正把贝叶斯随机性下放到低秩子空间中. 所有方法均独立运行 5 次, 每次训练 2000 步, 并记录测试环境上的最佳 OOD 准确率与总耗时. 这样的设计保证了本章比较的重点不在于网络容量大小的差异, 而在于**参数空间约束方式与不确定性建模方式本身**.

为保证正文数值可追溯, 本章表格中的均值、方差与耗时均直接对应仓库中的轻量结果文件 `cmnist/results/cmnist_ultimate_ablation_method_summary.csv`; 5 次独立运行的逐次明细保存在 `cmnist/results/cmnist_ultimate_ablation_seed_details.csv`. 后文涉及的百分点差值均由这两份文件中的原始数值四舍五入后得到.

5.2 主结果: OOD 表现、成本趋势与机制解释

5.2.1 五次独立运行的 OOD 精度对比

表 5.1 汇报了 5 次独立运行后的平均 OOD 精度与运行时间. 从结果可以观察到三个核心现象.

第一, **LoRA-BIRM (Route B)** 在 CMNIST 上取得了**最优的平均 OOD 精度**. 其测试精度达到 $70.33 \pm 0.90\%$, 相较于 IRMv1 的 $68.71 \pm 1.43\%$ 提升了 1.62 个百分点, 相较于 Full-BIRM 的 $68.96 \pm 0.90\%$ 也进一步提升了 1.37 个百分点. 这一结果说明, 当贝叶斯不确定性被约束在低秩子空间中时, 模型并未因参数压缩而损失泛化能力, 反而在分布外环境中表现出更强的稳健性.

第二, 仅有低秩结构而没有真实的低秩变分推断, 并不足以稳定提升 OOD 泛化. LoRA-BIRM (Route A) 的平均精度为 $68.24 \pm 1.49\%$, 不仅没有超过 Route B, 甚至略低于全参数基线. 这意味着低秩参数化虽然提供了结构瓶颈, 但若仍沿用确定性训练范式, 模型并不会自动获得更优的不变特征抽取能力. 真正产生增益的关键, 在于将低秩结构约束与贝叶斯不确定性探索联合起来.

第三, **Route B** 在均值更高的同时保持了较低的方差. 其标准差为 0.90, 与 Full-BIRM 持平, 但优于 IRMv1 和 Route A. 这表明本文方法并非偶然在个别随机种子下取得更优结果, 而是在重复实验中表现出更加稳定的收敛特征.

表 5.1: CMNIST 上 5 次独立运行的主结果.

方法	最佳 OOD 精度 (%)	平均运行时间 (s)
IRMv1	68.71 ± 1.43	5.5
Full-BIRM (Official)	68.96 ± 0.90	21.9
LoRA-BIRM (Route A)	68.24 ± 1.49	23.7
LoRA-BIRM (Route B)	70.33 ± 0.90	19.8

5.2.2 Route A 与 Route B 的差异解释

从理论视角看, 本章实验结果与第 4 章给出的动机分析是相容的. Full-BIRM 虽然引入了不确定性建模, 但其优化仍在全参数空间附近展开, 因而在小样本、多环境冲突的设置下, 对稳定因果表征的提炼能力并不突出. 相比之下, Route B 将随机性显式压缩到 LoRA 子空间中, 使模型只能在一个更受限、更平滑的低维流形内完成环境对齐. 这类结构性约束有助于削弱模型对高频虚假颜色模式的记忆, 并鼓励其优先保留跨环境共享的数字形状表征.

需要强调的是, CMNIST 毕竟属于低维玩具级任务. 因此, 本章的主要价值不在于单纯追求绝对分数的巨大领先, 而在于说明本文方法在最小可控平台上**能够工作、能够稳定工作, 且其收益方向与前述分析并不矛盾**. 对于一篇追求高水平学术质量的论文而言, 这一步是方法论成立的必要前提.

5.2.3 小规模平台上的训练代价比较

从运行时间看, IRMv1 仍是本实验中最快的方法, 平均仅需 5.5s 即可完成单次训练. 这一本身并不令人意外, 因为 IRMv1 不涉及任何显式的贝叶斯采样或低秩随机推断. 然而, 若只比较两类具备不确定性建模能力的方法, 则本文方法在当前小规模实现中仍表现出可观测的时间下降.

具体而言, Full-BIRM 的平均单次运行时间为 21.9s, 而 LoRA-BIRM (Route B) 为 19.8s, 在当前实验中以更高的 OOD 精度对应了约 9.6% 的训练耗时下降. 相比于 Route A 的 23.7s, Route B 也进一步减少了约 16.5% 的时间开销. 这说明在 CMNIST 这种小规模平台上, 低秩贝叶斯路线至少已经呈现出“**精度未降且代价未升高**”的可观测趋势.

必须指出, 本章尚不足以完整体现本文所强调的“算力墙”优势. 原因在于 CMNIST 的输入分辨率、网络深度与样本复杂度都较低, 因而全参数 BIRM 的计算代价还未膨胀到不可接受的程度. 换言之, 本章结果更像是一次**趋势验证**, 而不是最终的工程极限展示.

5.2.4 精度与稳定性的联合观察

图 5.2 汇总展示了本章实验中的精度均值、时间均值、精度-效率散点关系以及多次运行稳定性。从中可以更清楚地看到, Route B 位于右上方的更优区域: 它在 OOD 精度上领先于所有基线, 同时其运行时间又明显低于全参数 Full-BIRM. 这意味着本文方法并不是依靠简单地增加训练预算来“换取”精度, 而是在**参数空间设计与不确定性注入方式**两方面同时实现了更优平衡。




图 5.2: CMNIST 实验的总体结果可视化, 包括精度、耗时、精度-效率折中以及多次运行稳定性。

5.3 本章结论与向第六章的过渡

5.3.1 CMNIST 实验得出的三个结论

结合上述结果, 本章可以提炼出三个对全文至关重要的结论:

- **LoRA-BIRM 的有效性并非来自“LoRA”三个字本身**, 而是来自低秩结构与贝叶斯环境不变性约束的协同作用. Route A 与 Route B 的差异已经清楚说明了这一点.
- **在受控平台上, Route B 已经呈现出不弱于全参数 BIRM 的正向泛化-代价趋势**. 尽管这种趋势在 CMNIST 上尚未被极端放大, 但其方向与第 4 章的动机分析是吻合的.
- **CMNIST 足以支持方法在最小可控环境中的可行性, 但不足以证明方法“可扩展”**. 若要支撑一篇更高水平的论文, 还必须在更复杂、更高维、更接近真实视觉分布偏移的场景中继续验证本文方法的优势是否依旧成立.

5.3.2 为何需要进入 Spurious CIFAR

基于上述考虑, 本文选择将后续的 Spurious CIFAR-10 实验单独设置为第 6 章, 而不是与 CMNIST 放在同一章内混合叙述. 这样安排有两点学术上的必要性.

其一, **两类实验承担的论证职能不同**. CMNIST 是机理验证平台, 目标是回答“本文方法是否真正抓住了因果泛化所需的核心机制”; Spurious CIFAR-10 则是复杂场景扩展平台, 目标是回答“这种机制能否在更高维、更复杂、更具工程现实性的环境中保持有效”. 若将二者揉成同一章, 容易削弱论文的论证层次, 使读者分不清哪些结果是在验证原理, 哪些结果是在验证可扩展性.

其二, **高水平论文更强调叙事递进而非结果堆叠**. 合理的实验结构应当是: 先在最小闭环系统中验证方法具备可行性, 再在更复杂场景中检验它是否值得相信并具有推广价值. 因此, 本文保留第 5 章作为“核心机理仿真与验证”, 将第 6 章作为“复杂场景扩展与稳定性实测”, 这一章节安排更符合严谨的科研叙事逻辑.

第六章 复杂场景扩展与稳定性实测（基于 Spurious CIFAR）

第 5 章已经在 Colored MNIST 这一最小可控平台上验证了低秩贝叶斯因果学习的基本可行性。然而，CMNIST 的输入维度低、纹理复杂度弱、网络主干较浅，因而仍不足以回答一个更关键的问题：当数据从手写数字扩展到自然图像，当模型从小型 MLP 扩展到卷积神经网络，当虚假相关不再只是单一颜色翻转而是与图像通道、类别纹理和采样环境共同耦合时，低秩贝叶斯因果学习是否仍具有可扩展价值。

因此，本章将实验平台推进到 Spurious CIFAR 场景。本章的目标不是简单追求单个最高测试分数，而是从泛化精度、跨种子稳定性和训练预算三个维度考察方法在复杂视觉偏移中的实际表现。结果显示，BIRM 相较 ERM 与 IRMv1 具有更稳健的 OOD 表现；当前已归档的五种子 LoRA-BIRM 快照结果在平均历史峰值上与 BIRM 的过程最佳均值基本持平，但个别种子能够达到更高局部峰值，同时在当前快照搜索协议下将平均单种子运行时间从 345.68s 压缩到 128.78s。但同一组结果也暴露出一个重要限制：训练末端平均精度仅约 51.20%，最差种子的历史峰值为 52.90%，说明当前低秩搜索策略仍不能保证所有随机种子和所有环境子群都稳定学好。因而，本章给出的结论是审慎的：该方法当前最能成立的卖点，是**以较短训练预算搜索并保留高质量局部 OOD 峰值**，而距离完全稳健的 worst-group OOD 泛化仍需要进一步改进。为避免把实验设置、基线复现、方法设计和失败模式混在一起，本章按照“实验设置与评估口径 → 完整训练基线 → 低秩快照设计 → 主结果 → 稳定性边界”的顺序展开。

6.1 实验设置与评估口径

6.1.1 Spurious CIFAR 任务构造与环境划分

本章采用的复杂视觉任务以 CIFAR-10 图像为基础，构造二分类标签并人为注入与标签相关的虚假视觉信号。与 CMNIST 中直接给数字染色不同，CIFAR 图像本身已经包含丰富的纹理、背景和局部形状信息。因此，当训练环境中的某些通道模式或颜色掩码与标签高度相关时，深层卷积网络很容易将其当作捷径特征，而不是学习跨环境稳定的形状或语义结构。

实验采用多环境协议：训练阶段包含两个具有不同虚假相关强度的环境，测试阶段使用相关方向被显著改变的 OOD 环境。若模型学习的是因果特征，其分类器应当在测试环境中保持相对稳定；若模型依赖训练环境中的虚假通道或纹理捷径，则测试准确率会迅速下降。因此，Spurious CIFAR 比 CMNIST 更接近真实视觉分布偏移，也更适合检验低秩贝叶斯因果学习在高维视觉输入上的可扩展性。

为了避免数据划分或随机初始化造成偶然结论，本章对 ERM、IRMv1 与 BIRM 三个基线分别运行 5 个随机种子，即 11, 17, 23, 29, 37。每个种子记录训练过程中每 100 步的测试准确率以及最终测试准确率。对本文方法，本章当前主报告的是一组已归档的 5 种子低秩快照结果，并通过最佳快

照、最佳步数与训练末端精度来共同观察其稳定性边界。

6.1.2 对比方法、随机种子与报告口径

本章比较以下方法, 并统一在相同的多环境训练集与 OOD 测试集上报告结果:

- **ERM**: 不使用环境不变性约束, 直接最小化训练环境混合后的经验风险。
- **IRMv1**: 在经验风险之外加入一阶不变性梯度惩罚, 试图迫使不同环境共享同一个最优分类器。
- **BIRM**: 引入贝叶斯不变风险最小化思想, 通过不确定性建模缓解确定性 IRM 在强惩罚下的坍缩问题。
- **LoRA-BIRM Snapshot**: 将可训练扰动约束在低秩 LoRA 子空间中, 在搜索阶段同时维护当前模型与 EMA 模型, 并以验证到的最佳 OOD 快照作为输出。

在报告口径上, 三类完整训练基线均遵循“训练结束后给出最终模型, 同时记录过程最佳点”的常规协议, 并在 5 个随机种子下同时报告训练末端精度与历史最佳精度。对本文方法, 本章采用低秩快照式输出协议: 在固定预算内同时维护当前模型与 EMA 模型, 并记录训练过程中出现的最佳 OOD 快照。这里先给出统一的报告口径, 具体的低秩训练目标与快照流程将在基线结果之后单独展开。这样的安排有助于把“问题到底有多难”与“本文方法如何应对该问题”清楚地区分开来。

为保证正文数值可追溯, 本章只将已经归档到仓库的两组轻量结果文件作为主证据: ERM、IRMv1 与 BIRM 的 5 种子主基线来自 `cifar/results/official_cifar mnist_main_method_summary.csv` 与 `cifar/results/official_cifar mnist_main_seed_details.csv`; LoRA-BIRM 快照五种子结果来自 `cifar/results/official_cifar mnist_thesis312_snapshot_method_summary.csv` 与 `cifar/results/official_cifar mnist_thesis312_snapshot_seed_details.csv`。因此, 后文不再把未归档的早期筛选日志作为正文主证据, 而只保留能够直接回溯到结果文件的数值。

6.2 完整训练基线: ERM、IRMv1 与 BIRM

6.2.1 五种子最终精度与过程最佳精度

表 6.1 汇报了 ERM、IRMv1 与 BIRM 在 5 个随机种子上的结果。其中,“最终 OOD 精度”对应训练结束时的测试准确率,“过程最佳 OOD 精度”对应训练过程中每 100 步评估所得的最高测试准确率。两者的差异反映了训练动力学是否稳定: 若过程最佳明显高于最终精度, 则说明模型曾短暂找到较好的泛化解, 但后续优化又将其破坏。

表 6.1: Spurious CIFAR 上 ERM、IRMv1 与 BIRM 的 5 种子结果。

方法	最终 OOD 精度 (%)	过程最佳 OOD 精度 (%)	最差最佳精度 (%)
ERM	11.98 $\pm$ 1.48	43.20 $\pm$ 11.12	23.60
IRMv1	33.30 $\pm$ 3.71	56.44 $\pm$ 2.54	52.10
BIRM	55.02 $\pm$ 3.25	59.34 $\pm$ 2.17	56.50

结果首先表明, **ERM 在强分布偏移下几乎完全失效**. 其最终 OOD 精度仅为 11.98%, 远低于随机二分类水平. 这说明经验风险最小化并没有学习到跨环境稳定的判别依据, 而是高度依赖训练环境中与标签共现的虚假视觉线索. 一旦测试环境改变这些线索的相关方向, 模型预测便发生系统性反转.

其次, **IRMv1 能够在训练早期短暂提升 OOD 表现, 但最终稳定性不足**. 其过程最佳精度达到 56.44%, 明显高于 ERM, 说明不变性惩罚确实在一定程度上抑制了虚假特征. 但最终精度下降到 33.30%, 表明确定性 IRM 在复杂卷积特征空间中仍存在严重的优化漂移和后期坍缩现象. 这与第 4 章关于“有限样本过参数化会削弱 IRM 惩罚区分力”的分析是相符的.

最后, **BIRM 是三类基线中最稳健的方法**. 其最终 OOD 精度达到 $55.02 \pm 3.25\%$, 过程最佳精度达到 $59.34 \pm 2.17\%$, 最差种子的过程最佳精度也达到 56.50%. 与 IRMv1 相比, BIRM 的最终性能没有出现大幅崩溃, 说明贝叶斯不确定性确实能够缓解确定性不变性训练在复杂场景中的后期退化.

6.2.2 训练动力学解释

从训练日志可以看到, ERM 的训练损失很快下降并保持稳定, 但测试准确率持续走低. 这说明模型正在越来越好地拟合训练环境中的虚假相关, 而不是提取真正可迁移的因果特征. IRMv1 则呈现另一种模式: 在训练早期, 惩罚项能够将测试准确率推至 52%–60% 区间, 但随着训练继续, 梯度惩罚并不能稳定约束深层表征, 最终多个种子下降到 30% 左右.

BIRM 的动力学更加平滑. 尽管不同种子之间仍存在差异, 例如 seed 29 的最终精度仅为 49.20%, 但大多数种子能够维持在 55%–59% 附近. 这说明概率化的参数搜索为模型提供了额外的探索缓冲, 避免其过早收缩到某个依赖虚假特征的尖锐点估计解. 因此, 基线复现实验为本文进一步引入低秩贝叶斯结构提供了经验依据: 如果 BIRM 已能缓解 IRM 坍缩, 那么将这种不确定性进一步约束到低秩子空间, 有可能在保留泛化收益的同时降低搜索复杂度.

6.3 低秩快照式 LoRA-BIRM: 设计动机与训练流程

6.3.1 总体思路

基线结果说明了一个关键事实: 在 Spurious CIFAR 上, 单纯依赖经验风险会彻底失效, 确定性 IRM 即使在早期出现可观测高点也难以稳定保留, 而 BIRM 虽然更稳, 却仍需要较长训练预算. 因此, 本章对 LoRA-BIRM 的设计目标不是盲目追求更长训练, 而是尝试在保留 BIRM 式探索能力的前提下, 把搜索空间压缩到更小的低秩子空间, 并显式捕获训练轨迹中的局部高质量解.

LoRA-BIRM Snapshot 的出发点是将 BIRM 的贝叶斯不确定性建模与 LoRA 的参数高效搜索结合起来. BIRM 的优势在于通过概率化参数扰动缓解 IRMv1 的确定性优化坍缩, 但如果在卷积网络的全参数空间中直接进行贝叶斯搜索, 需要采样和正则化的变量过多, 训练成本也会随模型规模快速上升. 本章方法并不在完整权重空间中搜索泛化解, 而是将可训练随机性压缩到一个低秩子空间内, 使模型只通过少量方向调整分类边界.

设卷积骨干网络给出的图像表征为

$$h = f_{\theta_0}(x),$$

其中 θ_0 为主干参数. 在分类头处, LoRA-BIRM 将原始线性分类器扩展为

$$z(x) = W_0 h + b_0 + \frac{\alpha}{r} B A h,$$

其中 W_0, b_0 为基础分类器参数, $A \in \mathbb{R}^{r \times d}$ 与 $B \in \mathbb{R}^{1 \times r}$ 构成低秩增量路径, r 是 LoRA 秩, α/r 是缩放系数. 当 $r \ll d$ 时, 模型无法任意改写高维特征空间, 只能沿少数低秩方向修正决策边界. 这种限制一方面减少可训练自由度, 另一方面也削弱了模型记忆训练环境中特有纹理、颜色或通道噪声的能力.

为了保留贝叶斯探索能力, 本文进一步对低秩矩阵 B 建立变分后验:

$$q(B) = \mathcal{N}(B_\mu, \text{diag}(\exp(B_{\log \sigma^2}))),$$

并使用重参数化采样

$$B = B_\mu + \epsilon \odot \exp(0.5 B_{\log \sigma^2}), \quad \epsilon \sim \mathcal{N}(0, I).$$

因此, 随机性只发生在低秩增量通道上, 而不是扩散到整个卷积网络. 从训练专家视角看, 这相当于把全参数 BIRM 的高维后验搜索改写为低秩后验搜索: 搜索空间更小, 梯度估计更便宜, 但仍保留了通过随机扰动跳出尖锐虚假相关解的能力.

6.3.2 训练目标与环境约束

LoRA-BIRM Snapshot 的损失函数由经验风险、环境不变性惩罚、低秩 KL 正则和权重衰减组成. 令 ℓ_e 表示环境 e 上的分类负对数似然, 基础经验风险为

$$\mathcal{L}_{erm} = \frac{1}{|\mathcal{E}|} \sum_{e \in \mathcal{E}} \ell_e.$$

单独最小化该项会使模型倾向于利用训练环境中最容易降低损失的虚假相关. 因此, 算法需要额外约束不同环境的优化方向保持一致.

在 BIRM 型目标中, 本文沿用环境缩放变量的梯度一致性思想. 每次训练时从环境样本中构造两个子批次 s_1, s_2 , 对低秩后验采样得到输出 z_B , 并计算二者关于环境缩放变量 γ 的梯度乘积:

$$\mathcal{P}_{birm} = \mathbb{E}_{B \sim q(B)} [\langle \nabla_{\gamma} \ell_{s_1}(\gamma z_B), \nabla_{\gamma} \ell_{s_2}(\gamma z_B) \rangle].$$

如果模型学习到的是跨环境稳定特征, 不同环境对分类器缩放的梯度应当趋于一致; 如果模型依赖某个环境特有捷径, 不同子批次的梯度方向会出现冲突. 因而, 该惩罚项用于抑制只在局部环境成立的决策规则.

在软分組配置中, 算法还使用环境损失方差作为更直接的稳定性约束:

$$\mathcal{P}_{var} = \text{Var}_{e \in \mathcal{E}}(\ell_e).$$

该项鼓励不同环境的训练损失接近, 避免模型只优化样本量较大或更容易拟合的环境. Balanced-Group 配置则进一步强调类别与环境采样均衡, 减少平均损失被某一优势子群主导的风险.

综合来看, 本章低秩贝叶斯训练目标可写为

$$\mathcal{L} = \mathcal{L}_{erm} + \lambda_p \mathcal{P} + \lambda_{kl} D_{KL}(q(B) \| p(B)) + \lambda_2 \|\Theta\|_2^2,$$

其中 $\mathcal{P}$ 可取 $\mathcal{P}_{birm}, \mathcal{P}_{var}$ 或二者组合. KL 项限制低秩后验不要偏离先验过远, 权重衰减进一步抑制过拟合. 由于采样和 KL 计算只作用在低秩矩阵上, 该目标比全参数贝叶斯训练更适合有限预算下的复杂视觉 OOD 实验.

6.3.3 快照选择与训练流程

复杂视觉偏移中存在明显的早期泛化高峰: 模型可能在训练早期短暂捕获稳定语义特征, 但继续优化后又被训练环境中的颜色、纹理或通道捷径拉回. 因此, 本章不把最后一步模型作为唯一候选, 而是将训练过程视为受限预算内的低秩解搜索. 在每个评估间隔, 算法评估当前模型以及指数滑动平均模型:

$$\bar{\Theta}_t = \rho \bar{\Theta}_{t-1} + (1 - \rho) \Theta_t,$$

其中 ρ 为 EMA 系数. 当前模型反映最新梯度方向, EMA 模型则过滤 mini-batch 噪声并保留更平滑的参数轨迹.

快照选择规则为

$$\Theta^* = \arg \max_{\Theta_t \in \mathcal{S}} \text{Acc}_{val}(\Theta_t),$$

其中 $\mathcal{S}$ 为训练过程中产生的当前模型和 EMA 模型集合. 在严格部署场景中, Acc_{val} 应来自独立验证环境; 本章报告的过程最佳 OOD 精度主要用于受控比较不同方法在相同评估协议下能够到达的泛化区间, 因而更接近训练动力学诊断, 不应理解为真实应用中可以直接访问测试集.

完整流程可以概括为: 首先构建 Spurious CIFAR 多环境训练集并初始化 ResNet 特征提取器; 其次在分类头或高层映射中插入低秩贝叶斯 LoRA 路径; 然后在每一步抽取环境 mini-batch, 采样低秩扰动并计算经验风险、环境惩罚、KL 正则与权重衰减; 接着使用反向传播更新低秩参数并维护 EMA 轨迹; 最后按固定间隔评估候选快照, 在预算结束后返回验证表现最好的模型.

从机制上看, LoRA-BIRM Snapshot 不是简单地把 LoRA 加到 BIRM 上, 而是同时改变了搜索空间、正则化方式和模型选择准则. 低秩参数化负责压缩搜索空间, 贝叶斯采样负责提供局部探索, 环境惩罚负责约束跨环境一致性, 快照选择负责避免后期训练退化. 这四个部分共同解释了后续实验中“接近 BIRM 最佳精度区间, 但训练时间显著降低”的现象.

6.4 低秩快照实验: 五种子结果、局部高峰与预算折中

6.4.1 已归档的五种子快照主结果

当前仓库中已归档的 LoRA-BIRM 快照主结果来自 `cifar/results/official_cifar mnist_thesis312_snapshot_method_summary.csv` 与 `cifar/results/official_cifar mnist_thesis312_snapshot_seed_details.csv`. 基于这组可直接回溯的结果, 表 6.2 汇报了 IRMv1 $\rightarrow$ LoRA-BIRM 在 5 个随机种子上的历史最佳快照表现.

表 6.2: 已归档的 IRMv1 $\rightarrow$ LoRA-BIRM 五种子快照主结果.

方法	平均快照精度 (%)	标准差 (%)	最差种子 (%)	平均运行时间 (s)	平均最佳步数
IRMv1 $\rightarrow$ LoRA-BIRM	59.22	4.60	52.90	128.78	329.8

从均值看, 该配置的平均历史峰值为 59.22%, 与 BIRM 的过程最佳均值 59.34% 基本持平. 这说明在当前已归档的五种子口径下, LoRA-BIRM 还不能被表述为“已经稳定超过 BIRM”. 但从预算看, 其平均单种子运行时间为 128.78s, 相比 BIRM 的 345.68s 减少了约 62.7%, 说明低秩快照式搜索确实当前诊断协议下压缩了训练预算.

另一方面, 其最差种子的历史峰值仅为 52.90%, 仍低于 BIRM 的最差最佳精度 56.50%. 因而, 这组五种子结果更适合支持如下判断: 低秩快照路线已经能够以更短预算进入接近 BIRM 高点的区间, 但还没有把这种高点稳定转化为所有随机种子下都能守住的优势.

6.4.2 种子级别高峰与训练末端回落

仅看均值仍不足以揭示该方法的行为模式. 表 6.3 给出了 5 个随机种子的最佳快照、最佳步数与训练末端表现. 这些数据表明, LoRA-BIRM 的主要特征不是“末端稳定收敛”, 而是“在训练过程中搜索并捕获局部高峰”.

表 6.3: IRMv1 $\rightarrow$ LoRA-BIRM 五种子快照明细.

种子	最佳快照精度 (%)	最佳步数	快照标签	运行时间 (s)	训练末端精度 (%)
11	65.80	350	current	127.15	49.80
17	57.40	300	ema	129.43	50.10
23	63.00	300	ema	128.53	50.00
29	52.90	100	current	129.04	49.10
37	57.00	599	current	129.74	57.00

从表中可以看到, seed 11 与 seed 23 的最佳快照分别达到 65.80% 与 63.00%, 甚至高于 BIRM 五种子中观察到的最高过程最佳值 62.60%. 这说明低秩快照空间并非缺乏表达能力, 它确实能够在某些初始化与采样轨迹下找到相当强的 OOD 局部解. 但另一方面, seed 29 的最佳值只有 52.90%, 而且 5 个种子的训练末端平均精度仅约为 51.20%, 其中多数运行在训练后半程都回落到接近随机水平. 因而, 这组结果更支持“局部高峰搜索能力”这一卖点, 而不是“训练越久越稳、均值已经全面改写基线”这样的表述.

6.4.3 预算压缩与精度折中

除了 OOD 精度之外, 本章另一个关键观察是: 在当前快照搜索协议下, 低秩快照式 LoRA-BIRM 仍表现出可观测的时间压缩. 表 6.4 给出了 ERM、IRMv1、BIRM 与已归档五种子快照配置的平均单种子运行时间. 可以看到, LoRA-BIRM Snapshot 的平均运行时间为 128.78s, 相比 ERM 和 IRMv1 分别约快 2.44 $\times$ 与 2.49 $\times$, 相比 BIRM 约快 2.68 $\times$.

表 6.4: Spurious CIFAR 上不同方法的平均单种子运行时间与相对 BIRM 加速比.

方法	平均运行时间 (s)	相对 BIRM 加速比
ERM	314.20	1.10 $\times$
IRMv1	320.26	1.08 $\times$
BIRM	345.68	1.00 $\times$
IRMv1 $\rightarrow$ LoRA-BIRM Snapshot	128.78	2.68$\times$

这一时间压缩并不能简单归因于“LoRA 单步计算更快”。更准确地说，它来自三部分机制的叠加。第一，低秩参数化冻结了大部分骨干参数，将可训练自由度限制在 LoRA 子空间中，降低了优化搜索的复杂度。第二，快照式模型选择避免了在后期继续消耗大量无效训练预算；前文已经看到，复杂场景下的长训练并不一定带来更稳的泛化，反而可能破坏早期高质量 OOD 解。第三，低秩快照实验将训练目标从“等待最终收敛”改为“在受限预算内捕获最佳当前模型或 EMA 模型”。因此，这里更适合被理解为**当前过程最佳诊断协议下的预算压缩**，而不是单独由参数化形式带来的严格复杂度结论。

从预算-精度折中看，IRMv1 $\rightarrow$ LoRA-BIRM 的平均历史峰值为 59.22%，与 BIRM 的过程最佳均值 59.34% 非常接近，但平均运行时间从 345.68s 降至 128.78s。更合理的理解方式是：本文方法的优势并不主要体现为“最终稳定均值全面改写基线”，而是体现为**能够在较短预算内把搜索轨迹推进到接近甚至局部超过 BIRM 的峰值区间**，并通过快照保留机制把这些高点捕获下来。这一点对于后续向更大 CNN、视觉 Transformer 甚至基础模型迁移具有工程参考价值。




图 6.1: Spurious CIFAR 上 LoRA-BIRM Snapshot 的预算-峰值折中与训练末端回落。左图比较四种方法的平均运行时间与平均历史最佳 OOD 精度；右图展示 IRMv1 $\rightarrow$ LoRA-BIRM 在 5 个种子上的最佳快照与训练末端精度差距，并以 BIRM 的过程最佳均值与单种子最高值作为参考线。

图 6.1 把本章的核心叙事压缩到了同一张图中。左图显示，LoRA-BIRM Snapshot 在平均历史峰值几乎不低于 BIRM 的情况下显著缩短了运行时间；右图则显示，这种优势主要来自训练过程中的局部高点而非训练末端稳定收敛，多数种子都存在明显的 best-final gap，只有 seed 37 在训练末端基本保住了快照峰值。因而，这张图同时支持了“预算压缩”和“快照必要性”两条结论。

6.5 稳定性边界与失败模式

6.5.1 平均精度掩盖的最差环境问题

本章实验最重要的发现并不是某一配置取得了最高均值，而是历史高点与训练末端之间存在明显裂缝。在已归档的五种子结果中，历史最佳快照均值为 59.22%，但训练末端平均精度仅约 51.20%；与之对应，训练末端的 `final_ood_minacc_pct` 与 `final_ood_majacc_pct` 均值分别只有约 51.29%

与 50.40%。这说明即使模型在中途曾找到较好的 OOD 解, 若不通过快照保留机制及时截获, 后续训练仍可能把模型重新拉回接近随机水平。

因此, 对 Spurious CIFAR 这类复杂任务而言, 仅报告平均 OOD 精度是不够的。后续算法选择应当把评价目标从

$$\max \text{Acc}_{avg}$$

转向

$$\max \min_{g \in \mathcal{G}} \text{Acc}_g,$$

其中 $\mathcal{G}$ 表示由环境、类别或虚假属性组合形成的子群。只有当最差环境或最差子群的精度同步提高时, 才能说明模型真正摆脱了虚假特征。

6.5.2 为何低秩搜索会出现高峰但不稳定

低秩 LoRA 子空间一方面提供了容量瓶颈, 抑制模型记忆高维虚假噪声; 另一方面也限制了优化路径的可达性。当随机初始化与 mini-batch 序列恰好引导低秩方向对齐因果特征时, 模型可以在中途出现较高 OOD 快照; 但当低秩方向偏向某个环境特有模式时, 模型又很容易停留在 50% 左右。这解释了为什么同样的五种子设置下, seed 11 可以达到 65.80%, seed 23 可以达到 63.00%, 而 seed 29 的最佳值却只有 52.90%, 且其训练末端又回落到 49.10%。

此外, EMA 快照虽然能够保存早期高点, 但它本质上是一种模型选择机制, 不是不变性学习机制本身。如果训练目标没有显式优化最差环境, 那么最佳快照仍可能只是偶然出现的局部泛化高点。当前已归档结果中, 多个种子的训练末端 `final_ood_minacc_pct` 仍徘徊在 50% 左右, 说明稳定性并没有真正被抬起来。因此, 本章低秩快照实验的价值在于定位问题: LoRA-BIRM 的低秩空间并非没有表达能力, 但现有 objective 对最差环境的约束仍不充分。

6.6 本章结论

6.6.1 复杂场景下已经成立的结论

综合本章实验, 可以得到四点相对稳健的结论。

第一, **复杂视觉分布偏移显著放大了 ERM 的捷径学习问题**。ERM 在测试环境中的最终精度仅约 12%, 说明自然图像场景下的虚假相关比 CMNIST 更具欺骗性, 单纯依赖经验风险会导致系统性 OOD 失败。

第二, **BIRM 是 Spurious CIFAR 上三类完整训练基线中最稳健的方法**。BIRM 的最终精度达到 55.02%, 过程最佳达到 59.34%, 说明贝叶斯不确定性对于缓解确定性 IRM 的后期退化确实有效。

第三, **LoRA-BIRM 的更强卖点是“局部高峰搜索能力”, 而不是已经稳定超越 BIRM**。在当前已归档的五种子快照结果中, `IRMv1` $\rightarrow$ LoRA-BIRM 的平均历史峰值为 59.22%, 与 BIRM 的 59.34% 基本持平; 但 seed 11 与 seed 23 分别达到 65.80% 与 63.00%, 说明低秩快照空间确实能够在部分初始化下找到更高局部峰值。与此同时, 其最差种子仅为 52.90%, 训练末端平均精度也只有约 51.20%, 因而当前阶段更合理的说法仍然是: 该方法擅长搜索并保留局部高点, 但最差种子和最差环境稳定性仍未解决。

第四, 在当前过程最佳诊断协议下, 低秩快照式搜索带来了可观的训练预算压缩. IRMv1 $\rightarrow$ LoRA-BIRM 的平均单种子运行时间为 128.78s, 相比 BIRM 的 345.68s 对应约 $2.68\times$ 的加速或 62.7% 的时间下降. 因而, 即使稳定性仍需改进, 本文方法已经在复杂场景中展示了可观的工程扩展潜力.

6.6.2 仍待解决的问题与后续方向

本章结果也为后续工作指明了清晰方向. 首先, 训练目标应从平均风险转向 worst-group 风险, 将最差环境准确率直接纳入模型选择和优化, 以便把当前“能找到高峰”进一步转化为“能稳定守住高峰”. 其次, 低秩空间的 rank、学习率和 EMA 系数需要与环境不平衡程度联合调节, 避免单一高峰种子主导结论. 最后, 应建立比“最佳整体 OOD 精度”更严格的评价协议, 同时报告平均精度、最差种子、最差环境以及训练末端稳定性. 只有在这些指标上同时改善, 才能说明 LoRA-BIRM 真正完成了从 CMNIST 机理验证到复杂视觉 OOD 泛化的跨越.

第七章 Qwen 平台上的四算法对比实验与分析

前两章已经分别在 Colored MNIST 与 Spurious CIFAR 两个层次上验证了本文方法的机理可行性与复杂场景扩展能力。然而，上述结果仍主要停留在中小规模视觉模型上。若要真正回答“LoRA-BIRM 能否迁移到大语言模型语义表征空间”这一更核心的问题，还必须在参数规模显著更高、表征更抽象、训练动力学更敏感的预训练语言模型平台上进行直接验证。

基于此，本章进一步将实验对象扩展到 Qwen 平台，并围绕同一套 shortcut 训练与反转测试协议，对 ERM、IRMv1、BIRM 与本文提出的 LoRA-BIRM Snapshot 四种方法进行统一比较。与前述卷积网络实验不同，这里的关注点不再是训练预算压缩，而是进一步考察：在冻结式大模型基线已经具备一定泛化能力、且四种方法在当前端到端实现中的达到峰值时间处于同一量级的前提下，低秩贝叶斯因果微调是否仍能带来可观测的额外收益。需要先说明的是，本章当前结果仍以单次运行的历史峰值为主，更适合作为训练动力学诊断和可行性信号，不能替代多随机种子统计或基于独立验证集选择模型后的正式测试结论。

7.1 数据构造、环境划分与评估协议

7.1.1 shortcut 训练集的构造方式

本章采用 Qwen2.5-3B-Instruct 作为统一的大模型表征平台，数据来自本地 toxicity parquet 语料。我们首先将原始连续 toxicity 分数按阈值 0.5 二值化，得到二分类标签；随后选取 `male`、`female`、`LGBTQ`、`christian`、`muslim`、`black` 与 `white` 七个 identity 字段，并以它们的和定义样本是否包含显式身份线索。记该和为 `identity_sum`，当 `identity_sum > 0` 时视为“带身份提示”，否则视为“不带身份提示”。

在此基础上，我们人为构造一个带有强 shortcut 的训练集。训练集总共包含 20000 个样本，其中 toxic 类与 safe 类各取 10000 个。对 toxic 类样本，我们按照 90% “带身份提示”与 10% “不带身份提示”的比例抽样；对 safe 类样本，则反过来按照 10% “带身份提示”与 90% “不带身份提示”的比例抽样。经过这一步后，模型在训练阶段极易把“是否出现身份词”当作标签判断的捷径，而不是学习文本中的真正毒性语义。

训练环境进一步按身份提示与否划分为两个环境： E_1 由所有 `identity_sum > 0` 的样本组成， E_2 由所有 `identity_sum = 0` 的样本组成。因而，这里的环境标签并不是额外人工赋值，而是直接由 shortcut 特征是否出现来决定。这种构造方式使 Qwen 平台上的 OOD 实验与前述视觉环境实验在逻辑上保持一致：训练阶段的环境差异正是由虚假相关的存在形式触发的。

7.1.2 反转测试集的定义

为了检验模型是否真正摆脱了 shortcut, 本章不在与训练集同分布的验证集上打分, 而是构造了一个**反转测试集 (reversed test set)**. 具体做法是: 从未被训练使用的剩余样本中, 仅抽取两类样本组成测试集, 即“toxic 但不带身份提示”与“safe 且带身份提示”; 并将两类样本按相同数量拼接为平衡测试集. 这样得到的测试集总规模为 24074, 且其中身份提示与标签的相关方向相较训练集被整体翻转.

因此, 反转测试集的含义非常明确: 在训练集中, 身份提示大多与 toxic 标签共现; 而在反转测试集中, 模型会大量见到“不带身份提示的 toxic 样本”和“带身份提示的 safe 样本”. 如果模型只是记住了训练环境中的 shortcut, 它在该测试集上就会出现明显失效; 只有当模型真正依赖跨环境稳定的语义判别依据时, 才能保持较高准确率. 本章用反转测试准确率 (reversed test accuracy), 记作 Acc_{rev} , 作为四种方法的统一主指标.

7.2 四种算法的训练方式与运行配置

7.2.1 四种算法的训练方式

本章比较的方法如下:

- **ERM**: 冻结 Qwen 底座参数, 仅训练一个标准线性分类头, 直接最小化两个训练环境混合后的经验风险.
- **IRMv1**: 同样冻结 Qwen 底座, 训练标准分类头, 但在经验风险之外额外加入跨环境梯度惩罚, 以迫使两个环境共享相同的最优分类器.
- **BIRM**: 继续保持 Qwen 底座冻结, 但将分类头改写为轻量贝叶斯头. 该头包含共享高斯权重以及环境相关的附加线性项, 通过 KL 正则与环境惩罚共同优化, 用以缓解确定性 IRM 容易出现的坍缩问题.
- **LoRA-BIRM Snapshot**: 在贝叶斯分类头之外, 进一步解冻 Qwen 顶部若干层的低秩 LoRA 适配器. 训练时同时维护当前参数轨迹与 EMA 轨迹, 并在完整反转测试集上记录训练过程中的历史最优快照用于诊断比较.

这四种方法的核心区别在于可训练参数空间的大小与不确定性注入位置. ERM、IRMv1 与 BIRM 都属于**冻结底座 + 头部优化**范式, 只能在 Qwen 已有高层表征之上调整决策边界; LoRA-BIRM Snapshot 则允许模型在顶部 6 层内沿低秩方向对语义表征做有限重排. 因而, 第七章的比较本质上是在考察: 当 shortcut 已经嵌入到大模型高层表示中时, 仅靠头部约束是否足够, 还是需要受限的底座适配能力来完成进一步的因果修正.

7.2.2 统一评估协议与 LoRA-BIRM 超参数

Qwen 侧实验均在完整反转测试集上进行评估, 而不是在小样本随机子集上近似评估, 以避免噪声掩盖真实性能. 对 ERM、IRMv1、BIRM 与 LoRA-BIRM Snapshot 四种算法, 表中精度均取训练过程中的历史最优值, 以比较不同方法在当前统一实现下能够到达的峰值区间. 因而, 这些结果

更适合作为训练动力学诊断和可行性信号, 不应等同于基于独立验证集做模型选择后的正式测试结果. 其中, 三类冻结底座基线的“取最优耗时”来自各自历史最佳点对应的运行时间; 对 LoRA-BIRM Snapshot, 我们同时区分“取得最优快照的时间”和“完整预算运行时间”: 前者对应模型达到最佳性能所需的实际时间, 后者仅反映本轮实验原先设定的总搜索预算.

为保证正文数值可追溯, 本章四种方法的峰值时间与准确率直接对应 `qwen/results/qwen_erm_irmv1_birm_baseline_results.csv`、`qwen/results/qwen_lora_birm_stable_400_lr2e-5_pen3_ema98/summary.csv` 与 `qwen/results/qwen_lora_birm_stable_400_lr2e-5_pen3_ema98/step_history.csv`. 因而, 后文所有 checkpoint 数值都可直接回溯到这三份文件.

LoRA-BIRM Snapshot 的训练方式与前两类视觉实验中的快照搜索逻辑保持一致: 训练总步数预先设为 400, 每 25 步进行一次完整评估, 并在当前模型与指数滑动平均模型之间保留性能更优的候选快照. 表 7.1 给出了本章使用的主要参数. 这些配置的共同目的在于: 一方面保持低秩更新对子空间搜索的稳定性, 另一方面通过较慢的底座扰动速度尽量保留原始预训练语义结构.

表 7.1: Qwen 平台上 LoRA-BIRM Snapshot 的主要超参数.

最大步数	评估间隔	训练 batch	测试 batch	最大长度	分类头学习率	LoRA 学习率	权重衰减	最小学习率
400	25	8	16	128	8×10^{-4}	2×10^{-5}	0.01	1×10^{-6}
EMA 衰减	KL 权重	最大惩罚权重	惩罚预热比例	LoRA 秩 r	LoRA α	LoRA dropout	适配层数	
0.98	1×10^{-4}	3.0	2/3	8	16	0.05	顶部 6 层	

7.3 结果一：四种算法的总体结果对比

表 7.2 汇报了四种方法在 Qwen 平台上的历史峰值对比结果. 可以看到, 在当前未做特征缓存、并采用统一端到端实现的设定下, 四种方法达到各自历史峰值的时间均处于 34–38 分钟量级. 在这一相近的 time-to-best 区间内, LoRA-BIRM Snapshot 记录到最高的反转测试准确率 53.93%. 其中, 最强冻结式基线为 IRMv1, 其历史峰值为 51.77%; ERM 紧随其后, 为 51.73%; BIRM 则为 50.15%.

表 7.2: Qwen 平台上四种算法的历史峰值结果对比.

方法	底座更新方式	取最优耗时 (min)	反转测试准确率 (%)	相对最佳基线提升
BIRM	冻结底座, 仅训练贝叶斯头	34.22	50.15	-1.62 个百分点
ERM	冻结底座, 仅训练判别头	34.14	51.73	-0.04 个百分点
IRMv1	冻结底座, 仅训练不变性头	34.10	51.77	基线最优
LoRA-BIRM Snapshot (本文)	顶部 6 层 LoRA + 贝叶斯头	38.41	53.93	+2.16 个百分点

这一结果有三点值得强调. 第一, 在当前统一实现与单次运行协议下, **LoRA-BIRM Snapshot 记录到了最高的历史峰值**. 相较最优冻结式基线 IRMv1, 该峰值高出约 2.16 个百分点; 相较 ERM, 高出约 2.20 个百分点; 相较 BIRM, 高出约 3.77 个百分点. 但由于本章尚未完成多随机种子重复, 这一差值更适合被理解为“存在可观测信号”, 而不是统计显著性的正式结论.

第二, Qwen 章节当前更适合支持“相近 time-to-best 下的更高峰值”, 而不是效率结论. 四种方法达到各自历史峰值的 wall-clock 时间都在 34–38 分钟附近, 说明在当前未做特征缓存的端到

端实现中, 主要耗时仍来自大模型前向/反向与完整反转测试评估. 因而, 本章不把 LoRA-BIRM 的收益解释为速度优势, 而把它解释为在相近时间预算下取得了更高的历史峰值.

第三, 当前比较更直接支持“受限底座适配可能带来额外收益”, 而不是单独证明某个损失项绝对更优. ERM、IRMv1 与 BIRM 都保持底座冻结, 而 LoRA-BIRM Snapshot 允许在顶部 6 层做低秩适配. 因此, 这里更稳妥的结论是: 当仅靠轻量头部修正已经难以进一步提升时, 允许有限的高层表示重排可能提供额外空间; 至于这种收益究竟有多少来自 LoRA、多少来自贝叶斯化与环境约束, 仍需要更严格的同容量对照实验来拆分.

7.4 结果二: LoRA-BIRM 的训练动力学与快照现象

仅仅报告历史最优精度还不足以解释本文方法在 Qwen 上为何有效. 更关键的信息隐藏在训练曲线中: LoRA-BIRM Snapshot 在约 30 分钟时已经进入峰值平台, 随后在第 175 步达到精确最高点, 继续训练则出现明显回落. 图 7.1 给出了本章最优配置在不同评估步上的反转测试准确率曲线.




图 7.1: LoRA-BIRM Snapshot 在 Qwen 平台上的训练过程曲线. 虚线表示最优冻结式基线 IRMv1 的历史最优反转测试准确率.

从图中可以看到, 模型在前 75 步后便已迅速上升至 53% 以上, 第 125 步时以 27.42 分钟达到 53.75%, 已经进入本轮实验的峰值平台; 第 175 步以 38.41 分钟达到全程最高点 53.93%. 然而, 随着训练继续推进, 反转测试准确率并未进一步提高, 反而从第 200 步开始持续下降, 到第 375 步仅剩 51.56%, 已经回落到与冻结式基线接近的水平. 这说明在大模型低秩因果微调中, 更长训练并不必然对应更好的 OOD 泛化; 本轮实验之所以继续运行到 85.19 分钟, 主要是因为事先设置了 400 步搜索预算, 而不是因为最佳性能需要完整预算才能出现.

为了更紧凑地展示这一动力学过程, 表 7.3 选取了若干代表性 checkpoint. 可以看到, 第 75、125 与 175 步构成了一个明显的高性能平台区间; 其后模型精度单调走弱, 尤其在第 250 步后已经出现连续性回退.

这一现象与前几章在复杂视觉场景中的观察形成了呼应, 但在 Qwen 上表现得更加清晰. 对于大模型而言, LoRA 低秩通道提供了足够的自由度去修正 shortcut 依赖, 但这种修正主要发生在训练前半程. 一旦惩罚项持续增强、参数继续朝单一局部最优推进, 模型便可能重新对某些训练分布特有模式产生过拟合, 从而牺牲反转测试集上的泛化表现. 因此, 在当前实现下, 更合理的实际训练策

表 7.3: LoRA-BIRM Snapshot 在 Qwen 平台上的关键 checkpoint 表现.

训练步数	耗时 (min)	反转测试准确率 (%)	现象说明
25	5.47	49.17	仍处于热启动阶段, 尚未超过冻结式基线
75	16.44	53.65	快速进入有效 OOD 区间
125	27.42	53.75	约 30 分钟进入峰值平台
175	38.41	53.93	全程最佳快照, 当前模型优于 EMA
250	54.89	52.70	开始出现持续性性能回落
375	82.37	51.56	后期进一步退化, 已接近基线水平

略并不是盲目跑满预设步数, 而是在完整评估信号稳定后及时保留并停止于历史峰值附近.

7.5 结果分析与讨论

7.5.1 为何 LoRA-BIRM 可能高于冻结式基线的历史峰值

Qwen 实验最直接的结论是: 当底座允许进行受限的低秩语义重排时, 因果约束才真正拥有足够的施力空间. ERM、IRMv1 与 BIRM 三个基线虽然在冻结底座上都取得了 50% 以上的反转测试准确率, 说明 Qwen 预训练语义本身已经具备一定鲁棒性; 但它们之间差距极小, 表明单纯依赖头部层面的损失修正, 很难进一步摆脱深层表征中残留的 shortcut 痕迹.

LoRA-BIRM Snapshot 的优势恰恰在于它突破了这一限制. 通过在 Qwen 顶部 6 层施加秩为 8 的低秩更新, 模型不需要重写整个预训练网络, 却可以沿少量受控方向重构高层表示. 这些方向在贝叶斯扰动与环境惩罚的共同作用下, 更容易向跨环境稳定的判别子空间靠拢. 因此, 本文方法的提升并不是简单来自“参数更多”, 而是来自“参数自由度被约束在更适合做因果修正的低维流形中”.

7.5.2 为何最佳结果出现在前半程而非训练末端

从第 125 步已经接近峰值、第 175 步达到精确最高点、随后持续回落的事实来看, Qwen 平台上的 LoRA-BIRM 训练更像一个受限预算下的解搜索过程, 而不是传统意义上“越训越收敛”的单调优化过程. 在训练前半程, 低秩方向尚未过度贴合训练环境中的表层统计模式, 因而能够在经验风险与环境不变性之间形成相对平衡; 但当训练进一步推进时, 惩罚项与经验风险的长期耦合可能会把参数逐渐推向一个对训练分布更友好、却对反转环境更脆弱的区域.

这也解释了为什么本章对所有方法都采用历史最优快照作为报告结果, 而不是使用最后一步模型. 若直接使用训练末端模型, 不同算法会受到不同程度的后期回落影响, 比较口径并不公平. 对本文方法而言, 第 125 步到第 175 步之间已经完成主要性能提升, 后续继续运行只是本轮实验预算设置的结果. 因此, 更稳妥的说法是: 在当前实现中, 快照保留是获得较高历史峰值的重要模型选择机制. 它说明低秩因果微调中的较优解往往出现在训练轨迹的有限窗口内, 需要通过完整评估与历史保留机制才能被捕获; 但这仍不同于基于独立验证集做严格模型选择的正式测试流程.

7.5.3 Qwen 实验对全文结论的补充意义

若将本章与第 5、6 章合并来看, 本文的论证链条已经形成一个较完整的递进结构. 在 Colored MNIST 上, 本文验证了低秩贝叶斯因果学习在最小可控环境中的机理合理性; 在 Spurious CIFAR 上, 本文展示了该思路在复杂视觉偏移中的预算压缩潜力与稳定性边界; 而在 Qwen 平台上, 本章进一步说明该方法并不依赖于特定的卷积网络或图像纹理结构, 而是能够迁移到更高维、更抽象的语言模型语义空间中, 并在当前统一实现下记录到最高的反转测试历史峰值.

当然, 本章也同时暴露出一个新的工程事实: 当实验平台升级为大模型后, “如何稳定找到最佳快照并及时停止” 本身已经成为与 “如何设计损失函数” 同等重要的问题. 因而, 若未来继续推进 LoRA-BIRM 在更大参数量模型或更复杂文本 OOD 任务上的应用, 训练末端性能、历史最优性能与独立验证集选择机制三者之间的关系, 都需要被更系统地纳入算法设计.

7.6 本章小结

本章在 Qwen 平台上完成了 ERM、IRMv1、BIRM 与 LoRA-BIRM Snapshot 四种方法的统一历史峰值比较, 结论可以概括为以下三点. 第一, 在当前统一端到端实现与单次运行协议下, LoRA-BIRM Snapshot 以 53.93% 记录到了四种方法中的最高反转测试历史峰值, 相比最优冻结式基线 IRMv1 高出约 2.16 个百分点. 第二, 四种方法达到各自峰值的 wall-clock 时间处于相近量级, 因而本章更适合支持 “相近 time-to-best 下更高峰值” 的表述, 而不是效率结论. 第三, Qwen 上的训练曲线清楚表明, 后续跑满 400 步主要是实验预算设置导致的额外运行, 并不能继续提升 OOD 表现; 这说明在当前实现中, 历史峰值保留与及时停止是获得较高诊断指标的重要模型选择机制, 但后续仍需要多随机种子和独立验证集协议进一步确认这一现象是否稳健.

第八章 总结与展望

8.1 本文总结

本文围绕“大模型上的因果约束如何以可接受的工程成本落地”这一问题，对 LoRA-BIRM 的方法动机、实现机制与实验表现进行了系统整理。在问题层面，本文指出：传统 ERM 容易依赖 shortcut，确定性 IRM 在有限样本与深层网络中又容易出现优化漂移和后期坍缩，而全参数 BIRM 虽然提供了缓解退化的思路，但其变分推断开销与参数规模耦合过强，难以直接迁移到更大的模型平台。基于这一背景，本文提出将可训练随机性压缩到低秩子空间，并结合环境惩罚、KL 正则、完整评估、EMA 与快照保留机制，形成一条更具工程可执行性的 LoRA-BIRM 路线。

在理论与方法层面，本文并未试图给出一个过满的严格保证，而是建立了一条更保守的论证链条：低秩参数化能够压缩可训练自由度，小参数子空间上的贝叶斯化能够降低 KL 项的规模压力，因而为“不变性约束如何进入大模型”提供了合理的工程化近似。在实验层面，CMNIST 结果说明低秩贝叶斯路线在最小可控平台上是可行的；Spurious CIFAR 结果说明该方法更强的卖点不是已经稳定超过 BIRM，而是能够在五种子快照结果中以更短预算接近 BIRM 的过程最佳区间，并在个别种子上达到更高局部峰值；Qwen 结果则进一步表明，当允许有限的高层低秩适配并结合快照保留时，方法能够在相近 time-to-best 的条件下取得更高的历史峰值。

因此，本文当前最可靠的结论是：LoRA-BIRM 并未在所有保守口径下稳定改写现有基线，但它已经展示出一种值得继续推进的训练范式，即通过低秩参数化、贝叶斯环境约束和快照式模型选择，在受限预算内更高效地搜索高质量 OOD 解。这一结论既解释了本文在复杂视觉与大模型平台上的正向信号，也为后续进一步提升最差种子与最差环境稳定性留下了清晰问题空间。

8.2 未来研究方向

未来工作可以沿以下三个方向继续推进。第一，在目标函数层面，需要将评价与优化重点从平均精度进一步转向 worst-group 或 worst-environment 指标，使“能找到高峰”更稳定地转化为“能守住高峰”。第二，在训练协议层面，需要将历史最优、训练末端与独立验证集选择三者系统区分开来，建立更严格的多随机种子、多口径模型选择与报告规范。第三，在大模型扩展层面，仍有必要进一步拆分收益来源，即区分其中有多少来自低秩受限底座适配，有多少来自贝叶斯化，又有多少来自环境惩罚与快照保留机制本身。只有在这些问题上继续推进，LoRA-BIRM 才有可能从“高质量局部峰值搜索方案”进一步发展为在更广泛 OOD 任务中稳定可靠的因果微调方法。

参考文献

- [1] SHEN Z, LIU J, HE Y, et al. Towards out-of-distribution generalization: a survey[A/OL]. arXiv (2021). <https://arxiv.org/abs/2108.13624>.
- [2] HENDRYCKS D, DIETTERICH T. Benchmarking neural network robustness to common corruptions and perturbations[C]//International Conference on Learning Representations. 2019.
- [3] GEIRHOS R, JACOBSEN J H, MICHAELIS C, et al. Shortcut learning in deep neural networks[J]. Nature Machine Intelligence, 2020, 2(11): 665-673.
- [4] BEERY S, VAN HORN G, PERONA P. Recognition in terra incognita[C]//European Conference on Computer Vision. 2018: 456-473.
- [5] SCHÖLKOPF B, LOCATELLO F, BAUER S, et al. Toward causal representation learning [J]. Proceedings of the IEEE, 2021, 109(5): 612-634.
- [6] PETERS J, JANZING D, SCHÖLKOPF B. Elements of causal inference: foundations and learning algorithms[M]. MIT Press, 2017.
- [7] ARJOVSKY M, BOTTOU L, GULRAJANI I, et al. Invariant risk minimization[C]//arXiv preprint arXiv:1907.02893. 2019.
- [8] KRUEGER D, CABALLERO E, JACOBSEN J H, et al. Out-of-distribution generalization via risk extrapolation (REx)[C]//International Conference on Machine Learning. 2021: 5815-5826.
- [9] LIN Y, ZHU S, TAN L, et al. Bayesian invariant risk minimization[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 16021-16030.
- [10] KAPLAN J, MCCANDLISH S, HENIGHAN T, et al. Scaling laws for neural language models [A/OL]. arXiv (2020). <https://arxiv.org/abs/2001.08361>.
- [11] GULRAJANI I, LOPEZ-PAZ D. In search of lost domain generalization[C]//International Conference on Learning Representations. 2021.
- [12] WILES O, GOWAL S, STIMBERG F, et al. A fine-grained analysis on distribution shift[C]//International Conference on Learning Representations. 2022.
- [13] BLUNDELL C, CORNEBISE J, KAVUKCUOGLU K, et al. Weight uncertainty in neural networks[C]//International Conference on Machine Learning. 2015: 1613-1622.
- [14] JOSPIN L V, LAGA H, BOUSSAID F, et al. Hands-on bayesian neural networks – A tutorial for deep learning users[J]. IEEE Computational Intelligence Magazine, 2022, 17(2): 29-48.

- [15] HU E J, SHEN Y, WALLIS P, et al. LoRA: low-rank adaptation of large language models [C]//International Conference on Learning Representations. 2022.
- [16] ZHOU X, LIN Y, ZHANG W, et al. Sparse invariant risk minimization[C]//International Conference on Machine Learning. 2022: 27222-27244.
- [17] KINGMA D P, WELING M. Auto-encoding variational bayes[A/OL]. arXiv (2013). <https://arxiv.org/abs/1312.6114>.

致 谢

在此处撰写致谢辞. 感谢导师的悉心指导, 感谢同学学术和生活上的支持.